دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی
مهندسی کامپیوتر

تحلیل و مدل‌سازی سیگنال‌های مشاهده شده و ساختار گرافی در شبکه‌های اجتماعی

نگارش

آرین احدی‌نیا

استاد راهنما

حمیدرضا ربیعی

شهریور ۱۴۰۲

بسم الله الرحمن الرحیم

به نام خدا

دانشگاه صنعتی شریف

دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی

این پایان‌نامه به عنوان تحقق بخشی از شرایط دریافت درجه کارشناسی است.

عنوان: تحلیل و مدل‌سازی سیگنال‌های مشاهده شده و ساختار گرافی در شبکه‌های اجتماعی

نگارش: آرین احدی‌نیا

استاد راهنما: دکتر حمیدرضا ربیعی

امضاء

سپاس

«منّت خدای را عز و جل که طاعتش موجب قربت است و به شکر اندرش مزید نعمت. هر نفسی که فرو می رود ممدّ حیات است و چون بر می آید مفرّح ذات. پس در هر نفسی دو نعمت موجود است و بر هر نعمتی شکری واجب.» گلستان سعدی، دیباچه

چکیده

رشد سریع شبکه‌های اجتماعی و محدودیت‌های دسترسی به داده‌های آنها در سال‌های اخیر منجر به افزایش مشکل در به دست آوردن ساختار گراف زیرین این شبکه‌ها شده‌است. با این حال، اطلاعات فرآیندهای انتشار در این شبکه‌ها در دسترس هستند. الگوریتم‌های بسیاری برای استنتاج شبکه‌های زیرین با استفاده از این اطلاعات پیشنهاد شده‌اند. الگوریتم‌های پیشنهاد شده تنها بر استنتاج پیوندهای بیشتر تمرکز داشته‌اند و از حفظ ویژگی‌های ساختاری شبکه‌های اجتماعی غافل بوده‌اند. در این پایان‌نامه، ما روش نوآورانه‌ای ارائه می‌دهیم تا شبکه زیرین را با حفظ ویژگی‌های ساختاری آن استنتاج نماییم. این روش از اطلاعات سری زمانی فرآیندهای انتشار در قالب ماتریس انتقال مارکوف و همچنین شباهت‌های بین رئوس است که از نظر ساختاری می‌توان آن را در فرآیند انتشار مشاهده نمود استفاده می‌کند. به علاوه، این روش دارای پیچیدگی زمانی خطی نسبت به اندازه ورودی است و نسخه توزیع‌شده آن در چارچوب Map-Reduce نیز قابل مقیاس‌پذیری است. ما این روش پیشنهادی را بر روی شبکه‌های واقعی و مصنوعی آزمودیم. نتایج آزمایشی نشان دادند که روش پیشنهادی ضمن ارائه دقت بالا، زمان اجرای کمتری را برای استنتاج شبکه با حفظ ویژگی‌های ساختاری شبکه‌های اجتماعی از جمله ساختار مولفه‌ای، توزیع درجات و مولفه‌های همبند نیاز دارد.

کلیدواژه‌ها: شبکه‌های اجتماعی، استنتاج پیوند، انتشار اطلاعات

فهرست مطالب

۱ مقدمه ۱

۱-۱ تعریف و اهمیت موضوع ۱

۱-۲ مشارکت‌های صورت گرفته ۴

۱-۳ ساختار پایان‌نامه ۵

۲ کارهای پیشین ۶

۲-۱ روش‌های مبتنی تخمین بیشینه درست‌نمایی درختی ۶

۲-۲ روش‌های مبتنی بر تخمین بیشینه درست‌نمایی محدب ۷

۲-۳ روش‌های بر پایه مارکوف و گذار تصادفی ۷

۲-۴ روش‌های مبتنی بر استنتاج بیزی ۷

۲-۵ روش‌های مبتنی بر بازنمایی و خوشه‌بندی مبتنی بر بازنمایی ۸

۲-۶ جمع‌بندی ۸

۳ روش پیشنهادی ۱۰

۳-۱ تعریف مساله ۱۰

۳-۲ روش پیشنهادی ۱۱

۳-۲-۱ رفتار انتشاری ۱۳

۳-۲-۲ رفتار ساختاری ۱۴

۳-۳ جمع‌بندی ۱۵

۴ آزمون مدل ۱۸
۴-۱ معیارهای مقایسه ۱۸
۴-۱-۱ معیارهای بررسی صحت استنتاج ۲۰
۴-۱-۲ معیارهای بررسی حفظ مشابهت ساختاری ۲۰
۴-۱-۳ معیارهای اندازه‌گیری شاخصه‌های ساختاری ۲۱
۴-۲ مجموعه دادگان ۲۲
۴-۲-۱ دادگان ساختگی ۲۲
۴-۲-۲ دادگان حقیقی ۲۳
۴-۳ تحلیل آزمایشی مدل ۲۳
۴-۴ مقایسه نتایج ۲۵
۴-۴-۱ دادگان ساختگی ۲۷
۴-۴-۲ دادگان حقیقی ۳۴
۴-۵ جمع‌بندی ۳۶
۵ جمع‌بندی ۳۷
مراجع ۳۹
واژه‌نامه ۴۳

فهرست جداول

۱-۲ پیچیدگی زمانی کارهای مرتبط ۹

۱-۳ نمادهای ریاضیاتی استفاده شده ۱۱

۱-۴ جدول اختصارات استفاده‌شده برای معیارهای اندازه‌گیری ۱۹

۴-۲ مشخصه‌های مجموعه دادگان ساختگی ۲۳

۴-۳ مشخصه‌های مجموعه دادگان حقیقی ۲۴

۴-۴ نتایج روش پیشنهادی و سایر روش‌های رقیب بر روی مجموعه دادگان ساختگی ۳۳

۴-۵ نتایج روش پیشنهادی و سایر روش‌های رقیب بر روی مجموعه دادگان حقیقی . ۳۵

فهرست تصاویر

۱-۱ یک مثال از ساختار کلی مساله ۲

۱-۳ ساختار شبکه و دو آبشار مثالی بر روی آن ۱۳

۲-۳ روش پیشنهادی در چارچوب Map-Reduce ۱۷

۱-۴ نقشه حرارتی نشان‌دهنده رابطه ساختار جامعه‌ای شبکه با مقدار θ ۲۵

۲-۴ زمان اجرای مدل بر روی مجموعه دادگان ۴-۲آ مصنوعی و ۴-۲ب حقیقی . . ۲۶

۳-۴ زمان اجرای مدل بر روی دادگان مصنوعی با مقدار μ و اندازه مشاهدات مختلف ۲۷

۴-۴ عملکرد مدل‌های مختلف از منظر F1 بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار ۲۸

۵-۴ عملکرد مدل‌های مختلف از منظر NMI بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار ۲۹

۶-۴ عملکرد مدل‌های مختلف از منظر PWF بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار ۳۰

۷-۴ مقادیر معیارهای مختلف بر روی مجموعه دادگان ساختگی با مشاهده ۱۰۰۰۰ آبشار ۳۱

۸-۴ توزیع درجات رئوس در شبکه اصلی و شبکه استنتاج شده در مجموعه داده LFR1 با مشاهده ۱۰۰۰۰ آبشار ۳۲

فصل ۱

مقدمه

۱-۱ تعریف و اهمیت موضوع

در دنیای امروز، شبکه‌های اجتماعی بر خط نقش مهمی در تبادل اطلاعات ایفا می‌کنند. اطلاعات، ایده‌ها و رفتارها از طریق فرآیند **انتشار** در این شبکه‌ها منتشر می‌شوند. انتشار آلودگی در یک شبکه منجر به ایجاد یک دنباله از آلوده شدن کاربران به فرآیند انتشار یک محتوا می‌شود که به **آبشار** معروف است [۱]. آبشارهای انتشار، اطلاعات مفیدی در مورد شبکه‌های زیرین ارائه می‌دهند. بر اساس مطالعات قبلی به نظر می‌آید که رفتار انتشار و ساختار شبکه زیرین قویا به یک دیگر مرتبط هستند [۲، ۳، ۴]. درک بهتری از این رابطه، تجزیه و تحلیل دقیق‌تری از شبکه‌های اجتماعی و فرآیندهای آنها را امکان‌پذیر می‌سازد. هرچند که ممکن است به دلایل مختلف گراف زیرین یک شبکه اجتماعی برای انجام تحزیه و تحلیل در دسترس نباشد. اهم این دلایل عبارتند از:

- حفظ حریم شخصی و حساب‌های محافظت‌شده
- انتشار اطلاعات در وب‌سایت‌ها بدون ارجاع
- دسترسی محدود به داده‌ها به دلیل سیاست‌های شبکه‌های اجتماعی برخط

یک رویکرد برای حل مشکل عدم دسترسی به گراف شبکه زیرین، استنتاج آن با استفاده از سیگنال‌های دریافتی از فرآیندهای صورت گرفته بر روی آن مانند فرآیندهای انتشار است که با استفاده از آن به عنوان یک پیش‌پردازش می‌توانیم مسائلی را که نیاز به اطلاع از گراف شبکه زیرین دارند حل کنیم.

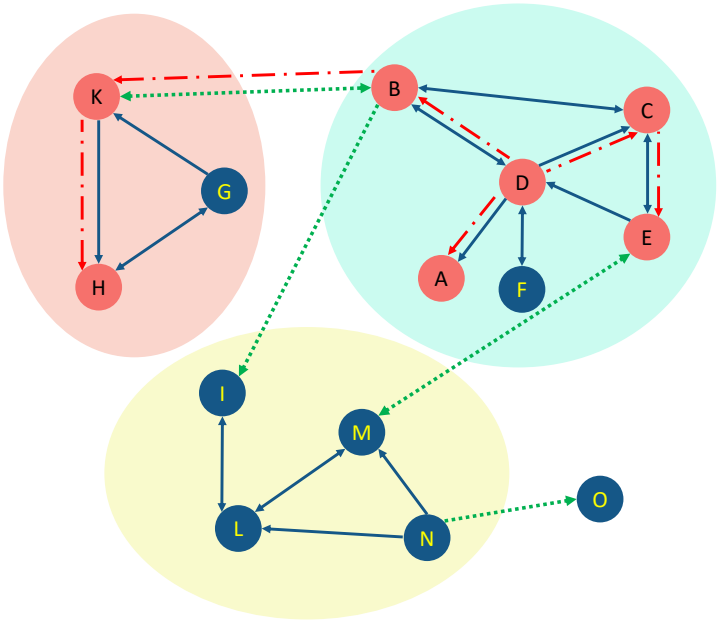

شکل ۱-۱: یک مثال از ساختار کلی مساله

همانطور که قبلاً اشاره شد، فرآیند انتشار از ساختار گراف شبکه زیرین تأثیر می‌پذیرد. بنابراین، مشاهده رفتار انتشار گره‌ها می‌تواند به ما کمک کند تا درکی از ساختار شبکه پیدا کنیم. در اکثر موارد، تنها مشاهده‌ای که موجود است، زمانی است که آلودگی به یک گره می‌رسد و آن گره آلوده می‌گردد. مساله ما، **استنتاج شبکه**، شامل یک دسته از مطالعاتی است که به هدف کشف شبکه زیرین از طریق استفاده از این زمان‌های آلوده شدن هر یک از راس‌ها در فرآیندهای انتشار مختلف صورت گرفته بر روی شبکه انجام می‌شود.

در شکل ۱-۱ یک مثال از ساختاربندی مساله ارائه شده است. هر راس در این گراف نشان‌دهنده یک کاربر در یک شبکه اجتماعی است. فلش‌های میان این رئوس نشان‌دهنده ارتباط میان کاربران است. در شبکه‌های اجتماعی گروهک‌هایی تحت عنوان جامعه[۱] شکل می‌گیرند که کاربران درون آن‌ها ارتباطات گسترده‌تری با یک‌دیگر نسبت به دیگر کاربران دارند. هر یک از رنگ‌های در برگیرنده کاربران نشان‌دهنده یکی از این جوامع است. فلش‌های آبی رنگ نشان‌دهنده ارتباطات **درون‌جامعه‌ای** و فلش‌های سبز رنگ نشان‌دهنده ارتباطات **بین‌جامعه‌ای** هستند. فلش‌های قرمز خط‌چین یک فرآیند انتشار را در این شبکه که از راس D شروع و دیگر راس‌ها را آلوده می‌کند نمایش می‌دهند.

شبکه‌های اجتماعی ویژگی‌های منحصربه‌فردی دارند که آنها را از گراف‌های تصادفی تفکیک می‌کند [۵، ۶]. توزیع درجه گره‌ها در شبکه‌های استنتاج شده باید مشابه شبکه زیرین اصلی باشند، به طوری که گره‌های تأثیرگذار با درجه بالا باقی بمانند. یکی از مهم‌ترین ویژگی‌های ساختاری شبکه‌های

[۱] Community

اجتماعی ساختار **مولفه‌ای**[۲] آنها است. هر مولفه در شبکه اجتماعی یک زیرشبکه چگال[۳] به نام **جامعه** است. این ویژگی‌ها تأثیر به‌سزایی بر تعاملات شبکه‌ای و نحوه انتشار اطلاعات در آنها دارند. یک استنتاج قابل اتکا باید ویژگی‌های ساختاری را حفظ کند.

نقشی که راس‌ها و پیوندهای مختلف در فرآیندهای شبکه مانند انتشار ایفا می‌کنند، متغیر است و می‌توان آن را به صورت زیر توصیف کرد [۷]:

- **پیوندهای درون‌جامعه‌ای** که راس‌ها در یک جامعه مشترک را به یکدیگر متصل می‌کنند. این راس‌ها به طور مکرر تعامل دارند بنابراین این پیوندها به عنوان پیوندهای قوی شناخته می‌شوند. راس‌هایی که تنها پیوند به سایر راس‌ها در جامعه خود دارند، به نام راس‌های مرکزی نام‌گذاری می‌شوند.

- **پیوندهای بین‌جامعه‌ای** که گره‌های اجتماع‌های مختلف را به یکدیگر متصل می‌کنند. به دلیل تعاملات کم بین این گره‌ها، آنها به عنوان پیوندهای ضعیف شناخته می‌شوند. راس‌هایی که حداقل یک پیوند بین اجتماعی دارند، به نام راس‌های مرزی شناخته می‌شوند. این راس‌ها نقش مهمی در انتشار اطلاعات در اجتماع‌های مختلف دارند.

تجزیه و تحلیل تعاملات بین اعضای شبکه یک مشکل پیوسته در شبکه‌های اجتماعی است [۸]. در واقع، احتمال اینکه یک فرد به یک آبشار آلوده بشود یا نه، به تصمیم همسایگان او در مورد آن آبشار وابسته است. در عین حال، این اتفاق بر تصمیمات آتی گره‌های همسایه در همان جامعه تأثیر می‌گذارد [۹]. اعضای یک جامعه از طریق پیوندهای درون‌جامعه‌ای قوی در یک مدت کوتاه به فرآیند انتشار آلوده می‌شوند. در مقابل، به دلیل پیوندهای ضعیف بین‌جامعه‌ای، انتشار آلودگی در بین دو جامعه با احتمال و سرعت پایین‌تری انجام می‌شود.

دیگر یافته جالب این است که در بسیاری از موارد، تأثیر پیوندهای ضعیف در یک فرآیند انتشار (به عنوان مثال نرخ پذیرش یک محصول جدید) قدرتمندتر از پیوندهای قوی است [۱۰، ۱۱]. ما سعی داریم این واقعیت‌ها را از طریق یک مثال توضیح دهیم. یک شبکه با سه اجتماع در شکل ۱-۱ نشان داده شده است. فرض کنید گره D توسط یک آبشار آلوده شود. سایر گره‌ها در اجتماع گره D نیز در معرض این آلودگی قرار خواهند گرفت و به احتمال بالا به دلیل تمایلات و اقدامات مشابه میان آنها، آلوده می‌شوند. بنابراین نرخ و میزان انتشار درون یک جامعه می‌تواند بالا باشد. اما چگونه آلودگی در سراسر شبکه منتشر می‌شود؟ به این منظور، آلودگی باید از اجتماع خارج شده و از طریق

[۲] Modular
[۳] Dense

یک راس مرزی مانند B به یک گره مرزی دیگر مانند K از یک جامعه مجاور سرایت کند. این تنها در صورت وجود حداقل یک پیوند بین‌جامعه‌ای مانند (B, I) یا (B, K) امکان‌پذیر است. بنابراین، پیوندهای ضعیف نقش مهمی در فرآیند انتشار در سراسر شبکه دارند. فرآیند انتشار ممکن است متوقف شود زیرا گذر از پیوندهای ضعیف کم‌احتمال‌تر است. به عبارت دیگر، ساختار جامعه‌ای مانع از انتشار گسترده آلودگی می‌شود. اجتماع‌ها می‌توانند یک آلودگی را متوقف کنند و در بیشتر موارد، وقتی یک آلودگی متوقف می‌شود، می‌توان یک اجتماع را تشخیص داد [۳، ۱۲].

چندین الگوریتم استنتاج شبکه پیشنهاد شده است، اما بیشتر آنها در طول فرآیند استنتاج ساختار مولفه‌ای شبکه را حفظ نمی‌کنند [۱۳]. با وجود دقت قابل قبول در تشخیص پیوندهای شبکه، ویژگی‌های ساختاری شبکه استنتاجی با شبکه زیرین همخوانی ندارند. در این پایان‌نامه، ما یک الگوریتم به نام DANI برای استنتاج شبکه با مشاهده فرآیندهای انتشار انجام شده بر روی آن ارائه می‌دهیم که شبکه‌های اجتماعی را از اطلاعات انتشار طوری استنتاج می‌کند که ساختار مولفه‌ای تا حد امکان حفظ شود.

۱-۲ مشارکت‌های صورت گرفته

- **استنتاج شبکه با حفظ ویژگی‌های ساختاری**: بسیاری از مسائل این حوزه که نیاز از اطلاع از ساختار مولفه‌ای شبکه دارند، از روش‌های تشخیص مولفه بر روی شبکه استنتاج شده بهره می‌برند. برای این امر نیاز است تا ویژگی‌های ساختاری در شبکه استنتاج شده حفظ شود. در ادامه نشان داده می‌شود که روش پیشنهادی عملکرد خوبی در حفظ ساختار شبکه دارد.

- **استنتاج شبکه با تعداد بیشتری از گره‌های متصل**: راس‌های شبکه در مسائل استنتاج، راس‌های فعالی هستند که در حداقل یک آبشار مشاهده‌شده شرکت می‌کنند. بنابراین هر راس فعال باید حداقل یک پیوند متصل داشته باشد تا از طریق آن پیوند فرآیند انتشار انجام شود. روش پیشنهادی شبکه‌های استنتاجی با تعداد بیشتری از راس‌های متصل تولید می‌کند که مشابه شبکه زیرین است. به عبارت دیگر، روش ما تعداد کمتری از راس منزوی نسبت به روش‌های قبلی تولید می‌کند.

- **قابلیت مقیاس‌پذیری بیشتر**: روش پیشنهادی الگوریتمی قابل هم‌روندسازی است که می‌توان از آن در داده‌های با ابعاد بزرگ استفاده کرد. این روش زمان اجرای کمتری نسبت به سایر روش‌های رقیب ارائه می‌دهد.

۱-۳ ساختار پایان‌نامه

ساختار این پایان‌نامه به این صورت خواهد بود. در فصل ۲ به بررسی کارهایی که پیشتر در این حوزه انجام شده‌اند می‌پردازیم. در فصل ۳ به تعریف دقیق مساله پرداخته و در ادامه آن مدل پیشنهادی برای حل آن تشریح می‌شود و در فصل ۴ مدل پیشنهادی را می‌آزماییم و نتایج آن را با دیگر کارهای مرتبط انجام شده در این حوزه مقایسه می‌کنیم و در نهایت در فصل ۵ جمع‌بندی از مطالب گفته شده ارائه می‌دهیم.

فصل ۲

کارهای پیشین

همان‌طور که در بخش‌های قبلی بحث شد، می‌خواهیم با استفاده از اطلاعات انتشار و در نظر گرفتن ساختار مولفه‌ای، یک شبکه را استنتاج کنیم. به طور دقیق، حوزه مرتبط با پژوهش ما، روش‌هایی هستند که با مشاهده فرآیندهای انتشار، به ویژه روش‌هایی که ویژگی‌های ساختاری را در نظر می‌گیرند، می‌باشد. در این بخش، این حوزه پژوهشی را توضیح می‌دهیم. هدف کلی تلاش در این حوزه، استنتاج پیوندهای یک شبکه با استفاده از اطلاعات انتشار است، که در بیشتر موارد زمان آلودگی راس‌ها در انتشارهای مختلف می‌باشد.

مطالعات تفصیلی کاملی مانند [۱۴، ۱۵، ۱۶] درباره مفاهیم این حوزه وجود دارد. در ادامه، به برخی از کارهای مهم مرتبط با این مساله می‌پردازیم.

۲-۱ روش‌های مبتنی تخمین بیشینه درست‌نمایی درختی

توجه ویژه به این حوزه با روش NetInf آغاز شد که هر آلودگی را به عنوان یک درخت در شبکه مدل می‌کند و با استفاده از یک الگوریتم گام‌به‌گام، شبکه را از این درخت‌ها با بهینه‌سازی یک تابع زیرمولفه‌ای استنتاج می‌کند [۱]. با وجود دقت بالای استنتاج این روش، مشکل عمده این روش زمان اجرای بالا آن در مجموعه داده‌های واقعی است. به علاوه، زمانی که ساختار شبکه مورد مطالعه با مدل درختی سازگار نباشد عملکرد NetInf کاهش می‌یابد [۱۷]. مشابه NetInf روش MultiTree نیز آلودگی را با درخت‌ها مدل می‌کند، اما تمام درخت‌های ممکن را مد نظر قرار می‌دهد [۱۸].

۲-۲ روش‌های مبتنی بر تخمین بیشینه درست‌نمایی محدب

روش CoNNIE با افزودن دانش احتمالی پیشین در مورد رابطه زمان‌های آلودگی، NetInf را بهبود می‌بخشد [۱۹]. روش NetRate نیز یک بهبود دیگر بر NetInf می‌باشد که به صورت زمانی تعاملات ناهمگن میان راس‌ها را استنتاج می‌کند که به واقعیت نزدیکتر است [۲۰]. روش InfoPath [۲۱] یک گسترش از NetRate برای شبکه‌های پویا می‌باشد. برخی از کارهای اخیر سعی در مد نظر قرار دادن ویژگی‌های ساختاری دارند. روش MADNI با استفاده از الگوهای مختلف مثلثی به عنوان دانش پیشین، سعی در استنتاج شبکه با انجام تخمین بیشینه‌گر احتمال پسین دارد [۲۲]. MADNI به استخراج الگوهای مثلثی بسته تمایل دارد و سایر الگوهای مثلثی را در نظر نمی‌گیرد. برخلاف روش‌های مبتنی بر زمان آلودگی، روش TENDS تنها به وضعیت آلودگی گره‌ها در هر آلودگی نیاز دارد و به زمان واقعی یا توالی آلودگی وابسته نمی‌باشد [۲۳].

۲-۳ روش‌های بر پایه مارکوف و گذار تصادفی

روش DNE انتشار را به عنوان یک گذار تصادفی مارکوف مدل می‌کند و سعی دارد یک وزن برای هر پیوند با استفاده از زمان برخورد تعریف کند [۲۴]. روش FastINF نیز از همین رویکرد برای تعیین وزن پیوندها استفاده می‌کند [۱۷]. این الگوریتم‌ها زمان اجرای کمی دارند و بر روی شبکه‌ها به خوبی کار می‌کنند، اما نمی‌توانند ساختار شبکه را حفظ کنند. روش‌هایی مانند DNE و FastINF تفاوتی بین انواع مختلف پیوندهای استخراج شده تشخیص نمی‌دهند. علیرغم دقت بالای آن‌ها، ساختار شبکه را در نظر نمی‌گیرند. اجرای الگوریتم‌های تشخیص اجتماع بر خروجی این روش‌ها منجر به انجام تشخیص اجتماع‌های متفاوتی نسبت به شبکه اصلی می‌شود، زیرا آن‌ها برخی از یال‌های ضعیف میان اجتماعی یا یال‌های قوی داخل اجتماعی را بازیابی نمی‌کنند.

۲-۴ روش‌های مبتنی بر استنتاج بیزی

[۲۵] یک روش استنتاج بیزی با استفاده از زنجیره مارکوف مونته‌کارلو (MCMC) و نمونه‌بردار TNT (Tie No Tie) برای نمونه‌برداری از پسین $P(G|C)$ ارائه می‌دهد. در این روش، بخش بیزی بر پایه یک گراف بدون جهت است و به دلیل روش نمونه‌برداری، همگرایی آن کند است. PBI ابتدا با استفاده از یک روش دیگر یک مقداردهی اولیه بدست می‌آورد تا یک شبکه از میزان تعاملات دو

به دوی رئوس پیدا کند و آن را به یک شبکه بدون جهت تبدیل می‌کند، سپس به طور گام‌به‌گام از نمونه‌بردار TNT و الگوریتم MCMC برای افزودن یا حذف یک پیوند تصادفی به این شبکه استفاده می‌کند [۱۳].

۲-۵ روش‌های مبتنی بر بازنمایی و خوشه‌بندی مبتنی بر بازنمایی

CENI راس‌های آبشارها را خوشه‌بندی می‌کند و برای گره‌هایی که در یک خوشه قرار دارند، پیوندها را با استفاده از تابع بقایی به همان شکل که در NetRate استفاده می‌شود، پیش‌بینی می‌کند [۲۶].

فرض کنید $i = (u, v)$ زوجی از دو راس باشد که حداقل در ۲۰ آبشار شرکت می‌کنند که زمان آلودگی راس u پیش‌تر از زمان آلودگی راس v باشد. یک گروه داده مجموعه‌ای از دوتایی‌ها $D^{(i)} = (x^{(i)}c, y^{(i)}c)$ است که $y^{(i)}c$ تفاوت زمان آلودگی زوج گره‌ها i در آبشار c را نشان می‌دهد، و $x^{(i)}c$ توصیف آبشار c که گره i در آن شرکت داشته است. KEBC تمام گروه‌های داده ممکن را با استفاده از روش Reproducing Kernel Hilbert Space در یک بازنمایی تعبیه می‌کند [۲۷] و با استفاده از K-means، آن‌ها را به دو خوشه تقسیم می‌کند و خوشه با تفاوت زمان آلودگی کمتر را برای نشان دادن پیوندها استفاده می‌کند، در حالی که راس‌ها در خوشه دیگر به طور مستقیم به هم وصل نمی‌شوند. اجرای KEBC مدت طولانی‌ای طول می‌کشد و به پارامترهای بازنمایی وابسته است. در REFINE، الگوی تعامل راس‌ها از چندین آبشار به یک ماتریس خلاصه می‌شود، و بازنمایی راس‌ها با استفاده از TSVD و خودرمزنگار ساخته می‌شود [۲۸]. بازسازی شبکه REFINE بر اساس تشابه کسینوسی محاسبه شده از ویژگی‌های بازنمایی شده کاربر است. این روش علاوه بر نیاز به زمان و حافظه زیاد، تنها بر روی گراف‌های بدون جهت عمل می‌کند.

۲-۶ جمع‌بندی

در نهایت از بین روش‌های معرفی شده، ۷ روشی که مشابهت با مساله ما دارند را برای بررسی دقیق‌تر و مقایسه انتخاب می‌کنیم. انتخاب این روش‌ها با رعایت گوناگونی انجام می‌شود تا عملکرد مدل‌های هر یک از این دسته‌ها در کنار مدل پیشنهادی سنجیده شود. در جدول ۲-۴ پیچیدگی زمانی این مدل‌ها را با دیگر مدل‌ها مقایسه کرده‌ایم که در آن M و N به ترتیب برابر تعداد آبشارهای مشاهده شده و تعداد رئوس شبکه است. از κ، η و d به عنوان ابعاد بازنمایی، تعداد تکرار و عمق شبکه عصبی استفاده شده است. روش‌های NetInf، NetRate و MultiTree از بهینه‌سازی محدب

استفاده می‌کنند و پیچیدگی زمانی اجرای آن‌ها وابسته به توپولوژی شبکه ورودی است.

جدول ۲-۱: پیچیدگی زمانی کارهای مرتبط

روش	پیچیدگی زمانی
NetInf	–
DNE	$O(MN^{۲})$
MultiTree	–
NetRate	–
KEBC	$O(MN^{۲}\kappa^{۳})$
REFINE	$O(N^{۲}M + N^{۳} + N\kappa^{۲d}\eta)$
PBI	$O(MN^{۲}\eta)$

فصل ۳

روش پیشنهادی

۳-۱ تعریف مساله

مجموعه آبشارهای مستقل $C = \{c_1, c_2, \ldots, c_M\}$ به عنوان ورودی مفروض است. هر c_i یک مجموعه از زوج‌های مرتبی شامل رئوس و زمان آلوده شدن آن‌ها به فرآیند انتشار در آبشار iام است که به صورت $c_i = \{(v_0, t_0^{(i)}), (v_1, t_1^{(i)}), \ldots, (v_n, t_n^{(i)})\}$ تعریف می‌شود. ترتیب شماره‌گذاری رئوس بر حسب زمان آلوده‌شدن آن‌ها به فرآیند انتشار است به طوری که $t_0^{(i)} < t_1^{(i)} < \cdots < t_n^{(i)}$. زمان آلوده شدن راس‌هایی که در فرآیند انتشار شرکت نمی‌کنند را بی‌نهایت در نظر می‌گیریم. هر راس تنها یکبار در فرآیند انتشار آلوده می‌شود و هر راس دقیقا توسط یک راس دیگر که پیش‌تر آلوده شده باشد، می‌تواند آلوده شود.

از آنجایی که ممکن است سرعت انتشار آبشارهای مختلف بر حسب محتوا آن‌ها و جامعه‌ای که آن آبشار در آن گسترش می‌یابد متفاوت باشد، به جای زمان آلوده شدن یک راس به فرآیند انتشار، شاخص ترتیبی آلوده شدن آن را در نظر می‌گیریم. بنابرین از این پس به جای تعریفی که پیشتر ارائه کردیم، از تعریف ۳-۱ برای معرفی یک بردار آبشار استفاده می‌کنیم که در آن r نمایه آخرین راسی است که به آبشار آلوده شده و پس از آن زمان آلوده‌شدن دیگر رئوس بی‌نهایت است.

$$\tilde{c}_i = \{(v_0, l_{v_0}^{(i)}), (v_1, l_{v_1}^{(i)}), \ldots, (v_r, l_{v_r}^{(i)})\} \tag{۳-۱}$$

حال می‌خواهیم با ورودی مجموعه بردارهای آبشار مشاهده شده، گراف زیرین مجهول G^* را استنتاج کنیم. $G^* = (V, E)$ گرافی شامل رئوس شرکت کرده در فرآیند انتشار و تمام پیوندهای جهت‌دار ممکن میان آن‌ها است. می‌خواهیم که برای هر یک از این پیوندها بین دو راس مفروض u

و v یک وزن متناظر با وجود آن پیوند در گراف زیرین اصلی به صورت $۰ \leqslant w_{ij} \leqslant ۱$ محاسبه کنیم به طوری که در گراف زیرین تخمین‌زده‌شده ویژگی‌های ساختاری شبکه اجتماعی حفظ گردد. هر یک از وزن‌ها باید طوری تخصیص یابند که مطابق معادله ۳-۲ احتمال درست‌نمایی وقوع آبشارهای مشاهده شده بر روی آن گراف بیشینه شود.

$$G' = \underset{G|۰\leqslant w\leqslant ۱}{\operatorname{argmax}} P(C|G) \tag{۳-۲}$$

برای بهبود خوانایی نمادهای استفاده شده در این فصل در جدول ۳-۱ به اختصار آورده شده‌اند.

۳-۲ روش پیشنهادی

برای تخمین وزن w_{ij} از دو ویژگی رفتار انتشاری و ساختاری به طور هم‌زمان استفاده می‌کنیم تا ویژگی‌های ساختاری شبکه‌های اجتماعی حفظ گردد.

برای سادگی فرض می‌کنیم که احتمال وجود هر یک از پیوندها در یک گراف مستقل از دیگر

جدول ۳-۱: نمادهای ریاضیاتی استفاده شده

نماد	تعریف
N، M	تعداد راس‌های و آبشارهای مشاهده شده
V، E	مجموعه راس‌ها و تمام پیوندهای جهت‌دار در گراف کامل شبکه زیرین
G^*، G، G'	گراف (شبکه) زیرین، کامل و استنتاج شده
(u, v)	پیوند جهت‌دار از راس u به راس v
c_i، C	iامین آبشار در مجموعه آبشارهای C
$t_u^{(i)}$	زمان آلوده شدن راس u به فرآیند انتشار آبشار iام
$\tilde{c}_i$، $\tilde{C}$	iامین بردار آبشار در مجموعه بردارهای آبشار $\tilde{C}$
$l_u^{(i)}$	نمایه ترتیبی آلوده شدن راس u به فرآیند انتشار آبشار iام
λ_{uv}،$\lambda_{uv}^{(i)}$	رفتار مشترک رئوس u و v در فرآیند انتشار در آبشار iام و در همه آبشارها
$In(u)$	مجموعه آبشارهایی که راس u در آنها شرکت داشته است
θ_{uv}	رفتار ساختاری مشترک رئوس u و v
w_{uv}	احتمال وجود یال بین دو راس u و v در گراف استنتاج شده
$\overline{n_c}$	تعداد میانگین رئوس آلوده شده در زمان غیر از بی‌نهایت در مجموعه آبشارها

پیوندها است بنابرین می‌توانیم احتمال وقوع گراف را مطابق معادله ۳-۳ به صورت حاصل ضرب احتمال وجود هر یک از یال‌های آن در نظر بگیریم.

$$P(G) = \prod_{(u,v)\in G} P(u,v) \tag{۳-۳}$$

همچنین در نظر می‌گیریم که فرآیند انتشار از مدل آبشارهای مستقل[۱] پیروی می‌کند که بر حسب آن طبق معادله ۳-۴ احتمال وقوع آبشارهای مشاهده شده بر روی گراف G را می‌توانیم به صورت حاصل ضرب احتمال وقوع هر یک از این آبشارها در نظر بگیریم.

$$P(C|G) = \prod_{i=۱}^{i=M} P(c_i|G) \tag{۳-۴}$$

بنابرین احتمال انتشار آبشار c_i بر روی گراف G را می‌توانیم به صورت معادله ۳-۵ بازنویسی کنیم.

$$P(c_i|G) = P(c_i|\{(u,v)\}_{(u,v)\in E}) = \frac{\prod_{(u,v)\in E} P((u,v)|c_i) \times P(c_i)}{\prod_{(u,v)\in E} P(u,v)} \tag{۳-۵}$$

که در آن $P(c_i|(u,v))$ احتمال انتشار یک آبشار از طریق پیوند جهت‌دار u به v است. بنابرین در نهایت احتمال معادله ۳-۴ را می‌توانیم به صورت معادله ۳-۶ بازنویسی کنیم.

$$\log(P(C|G)) \propto \log\left[\prod_{i=۱}^{i=M} \prod_{(u,v)\in G} P\left(c_i|(u,v)\right)\right] \propto \sum_{(u,v)\in G} \sum_{c_i\in C} \log(P(c_i|(u,v)) \tag{۳-۶}$$

با توجه به [۲۹، ۲۵، ۱] احتمال $P(c_i|(u,v))$ از توزیع نمایی پیروی می‌کند. بنابرین می‌توانیم آن را به صورت معادله ۳-۷ بازنویسی کنیم که در آن $\lambda_{uv}^{(i)}$ نمایانگر رفتار انتشاری دو راس u و v در آبشار iام و θ_{uv} نمایانگر رفتار ساختاری این دو راس است.

$$P(c_i|(u,v)) = e^{-\frac{\lambda_{uv}^{(i)}}{\theta_{uv}}} \tag{۳-۷}$$

در نهایت پاسخ مساله را می‌توانیم با حل مساله بهینه‌سازی معادله ۳-۸ به‌سادگی بدست آوریم.

$$G' = \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} \sum_{c_i\in C} \log(P(c_i|(u,v)) \tag{۳-۸}$$

---

[۱] Independent Cascades

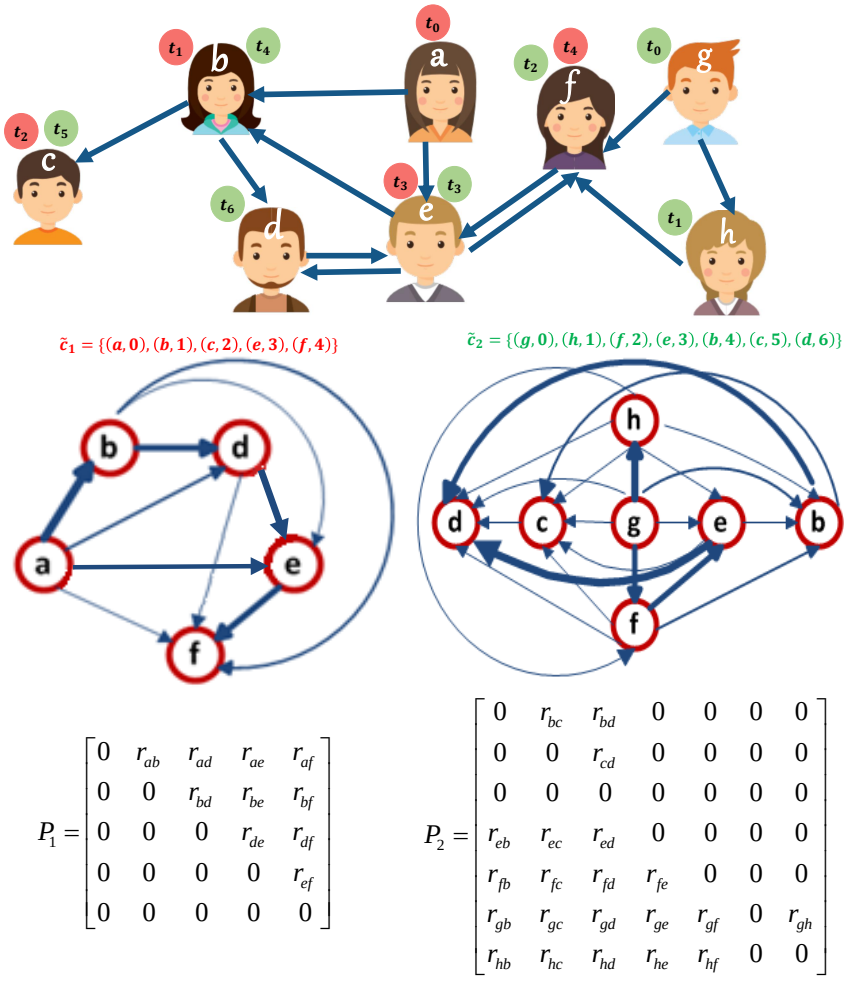

$$P_1 = \begin{bmatrix} 0 & r_{ab} & r_{ad} & r_{ae} & r_{af} \\ 0 & 0 & r_{bd} & r_{be} & r_{bf} \\ 0 & 0 & 0 & r_{de} & r_{df} \\ 0 & 0 & 0 & 0 & r_{ef} \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \qquad P_2 = \begin{bmatrix} 0 & r_{bc} & r_{bd} & 0 & 0 & 0 & 0 \\ 0 & 0 & r_{cd} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ r_{eb} & r_{ec} & r_{ed} & 0 & 0 & 0 & 0 \\ r_{fb} & r_{fc} & r_{fd} & r_{fe} & 0 & 0 & 0 \\ r_{gb} & r_{gc} & r_{gd} & r_{ge} & r_{gf} & 0 & r_{gh} \\ r_{hb} & r_{hc} & r_{hd} & r_{he} & r_{hf} & 0 & 0 \end{bmatrix}$$

شکل ۳-۱: ساختار شبکه و دو آبشار مثالی بر روی آن

۳-۲-۱ رفتار انتشاری

آلوده شدن رئوس در شبکه را می‌توانیم به صورت یک فرآیند مارکوف مشابه شکل ۳-۱ در نظر بگیریم که آلوده شدن هر فرد احتمالی برای آلوده شدن همسایگان آن فرد ایجاد می‌کند. هر آنچه که زمان از آلوده شدن یک راس بگذرد، احتمال آنکه همسایگانش را آلوده کند کاهش می‌یابد. بنابرین هر آنچه اختلاف نمایه ترتیبی دو راس u و v افزایش پیدا کند، احتمال آلوده شدن راس v توسط راس u از طریق یال (u,v) کاهش پیدا می‌کند. بنابرین برای هر دو راس u و v که $l_v^{(i)} > l_u^{(i)}$ باشد، طبق معادله ۳-۹ احتمال گذر آبشار c_i از یال مابین دو راس با افزایش اختلاف نمایه ترتیبی کاهش پیدا می‌کند.

$$P(c_i|(u,v)) \propto \frac{۱}{l_v^{(i)} - l_u^{(i)}} \tag{۳-۹}$$

با گذر زمان در انتشار هر آبشار، هر آنچه راس‌های بیشتری آلوده می‌شوند، احتمال اینکه راس v به طور خاص توسط راس u آلوده شود کاهش پیدا می‌کند. بنابرین طبق معادله ۳-۱۰ با افزایش نمایه

ترتیبی راس v در هر آبشار، احتمال آنکه آن راس خصوصا توسط راس u آلوده شده باشد کاهش می‌یابد.

$$P(c_i|(u,v)) \propto \frac{۱}{l_v^{(i)}} \tag{۱۰-۳}$$

بنابرین می‌توان متغیر $d_{uv}^{(i)}$ را با در نظر گرفتن هر دو رابطه ۳-۹ و ۳-۱۰ به صورت معادله ۳-۱۱ تعریف کنیم و با بهنجارسازی آن $\lambda_{uv}^{(i)}$ را به طریق معادله ۳-۱۲ تخمین بزنیم.

$$d_{uv}^{(i)} = l_v^{(i)} \times (l_v^{(i)} - l_u^{(i)}) \tag{۱۱-۳}$$

$$\lambda_{uv}^{(i)} = \frac{d_{uv}^{(i)}}{\sum\limits_{y \in V} d_{uy}^{(i)}} \tag{۱۲-۳}$$

۳-۲-۲ رفتار ساختاری

ساختار جامعه‌ای یکی از مهم‌ترین ویژگی‌های شبکه‌های اجتماعی است که تاثیر فراوانی در نحوه گسترش یک آبشار در شبکه دارد [۳، ۴، ۱۲، ۳۰]. برای بررسی میزان تعامل ساختاری دو راس در یک جامعه از شاخص جاکارد [۳۱] که به صورت معادله ۳-۱۳ تعریف می‌شود استفاده می‌کنیم.

$$\theta_{uv} = \frac{|In(u) \bigcap In(v)|}{|In(u) \bigcup In(v)|} \tag{۱۳-۳}$$

که در آن $In(u)$ طبق معادله ۳-۱۴ مجموعه آبشارهایی است که u در آن‌ها شرکت کرده است. دقت بفرمایید که صورت این معیار برای یال جهت دار بین دو راس u و v تنها آبشارهایی را در نظر می‌گیرد که u پیش‌تر از v در آبشار آلوده شده باشد.

$$In(u) = \begin{cases} \bigcup\limits_{i=۱}^{M} \{i\} & if(u \in \tilde{c}_i) \\ \emptyset & else \end{cases} \tag{۱۴-۳}$$

بنابرین در نهایت می‌توانیم گراف را به صورت معادله ۳-۱۵ استنتاج کنیم.

$$\begin{aligned} G' &\propto \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} \sum_{c_i \in C} \frac{-\lambda_{uv}^{(i)}}{\theta_{uv}} \\ &= \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} \frac{-\sum_{c_i \in C} \lambda_{uv}^{(i)}}{\theta_{uv}} \\ &= \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} \frac{-\lambda_{uv}}{\theta_{uv}} \end{aligned} \tag{۳-۱۵}$$

که در آن $\lambda_{uv} = \sum_{c_i \in C} \lambda_{uv}^{(i)}$ تعریف می‌شود. در نهایت برای استنتاج گراف به رابطه ۳-۱۶ می‌رسیم.

$$G' \propto \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} \frac{\theta_{uv}}{\lambda_{uv}} \tag{۳-۱۶}$$

در نهایت با توجه به ارتباطی که مابین احتمال وقوع یک یال و $\frac{\theta_{uv}}{\lambda_{uv}}$ وجود دارد، وزن هر یال را به صورت $w_{uv} = \frac{\theta_{uv}}{\lambda_{uv}}$ تعریف می‌کنیم و نهایتا معادله ۳-۱۶ را به صورت ۳-۱۷ بازنویسی می‌کنیم.

$$G' \propto \underset{G}{\operatorname{argmax}} \sum_{(u,v)\in G} w_{uv} \tag{۳-۱۷}$$

پیچیدگی زمانی: اگر در آبشار c_m تعداد n_{c_m} راس آلوده شده باشند، تعداد $\binom{n_{c_m}}{۲}$ جفت برای بررسی وجود دارد. بنابرین پیچیدگی زمانی مدل پیشنهادی از $O(M \times \overline{n_c}^{۲} \times N)$ خواهد بود. یکی از ویژگی‌های ممتاز مدل پیشنهادی رابطه خطی آن با اندازه ورودی است که نشان‌دهنده مقیاس‌پذیری آن است.

۳-۳ جمع‌بندی

در نهایت الگوریتم را می‌توان به صورت زیر خلاصه کنیم.

الگوریتم فوق در چارچوب Map-Reduce به صورت شکل ۳-۲ قابل پیاده‌سازی است. با پیاده‌سازی مدل در این چارچوب می‌توانیم آن را به طور توزیع شده برای اجرا بر روی دادگان بزرگ استفاده کنیم.

الگوریتم ۱ روش پیشنهادی

ورودی: مجموعه آبشارهای مشاهده‌شده $C = \{c_1, \ldots, c_M\}$

خروجی: شبکه استنتاج شده G'

به ازای هر $c_m = \left\{\left(v_i, t_i^{(m)}\right)\right\} \in C$:

$l_{v_i}^{(m)} = index(t_i^{(m)})$

$\tilde{c}_m = \left\{\left(v_i, l_{v_i}^{(m)}\right)\right\}$

به ازای هر راس $u \in \tilde{c}_m$ و $v \in \tilde{c}_m$:

اگر $l_u^{(m)} < l_v^{(m)}$:

$d_{uv}^{(i)}$ را طبق معادله ۳-۱۱ حساب کن

به ازای هر $(u, v) \in d^{(i)}$:

$$\lambda_{uv}^{(i)} \leftarrow \frac{d_{uv}^{(i)}}{\sum_{y \in V} d_{uy}^{(i)}}$$

$$\lambda_{uv}^{t} \leftarrow \lambda_{uv}^{t} + \lambda_{uv}^{(i)}$$

به ازای هر $(u, v) \in \lambda^t$:

$$\lambda_{uv}^{t} \leftarrow \frac{\lambda_{uv}^{t}}{\sum\limits_{y \in V} \lambda_{uy}^{t}}$$

$$\lambda_{uv} \leftarrow \lambda_{uv} + \lambda_{uv}^{t}$$

به ازای هر $(u, v) \in \lambda$:

$$w_{uv} = \frac{\theta_{uv}}{\lambda_{uv}}$$

به ازای هر $G \in E_{ij}$:

اگر $(w_{ij} > 0)$:

$G' \leftarrow G' \bigcup \{E_{ij}\}$

برگردان G'

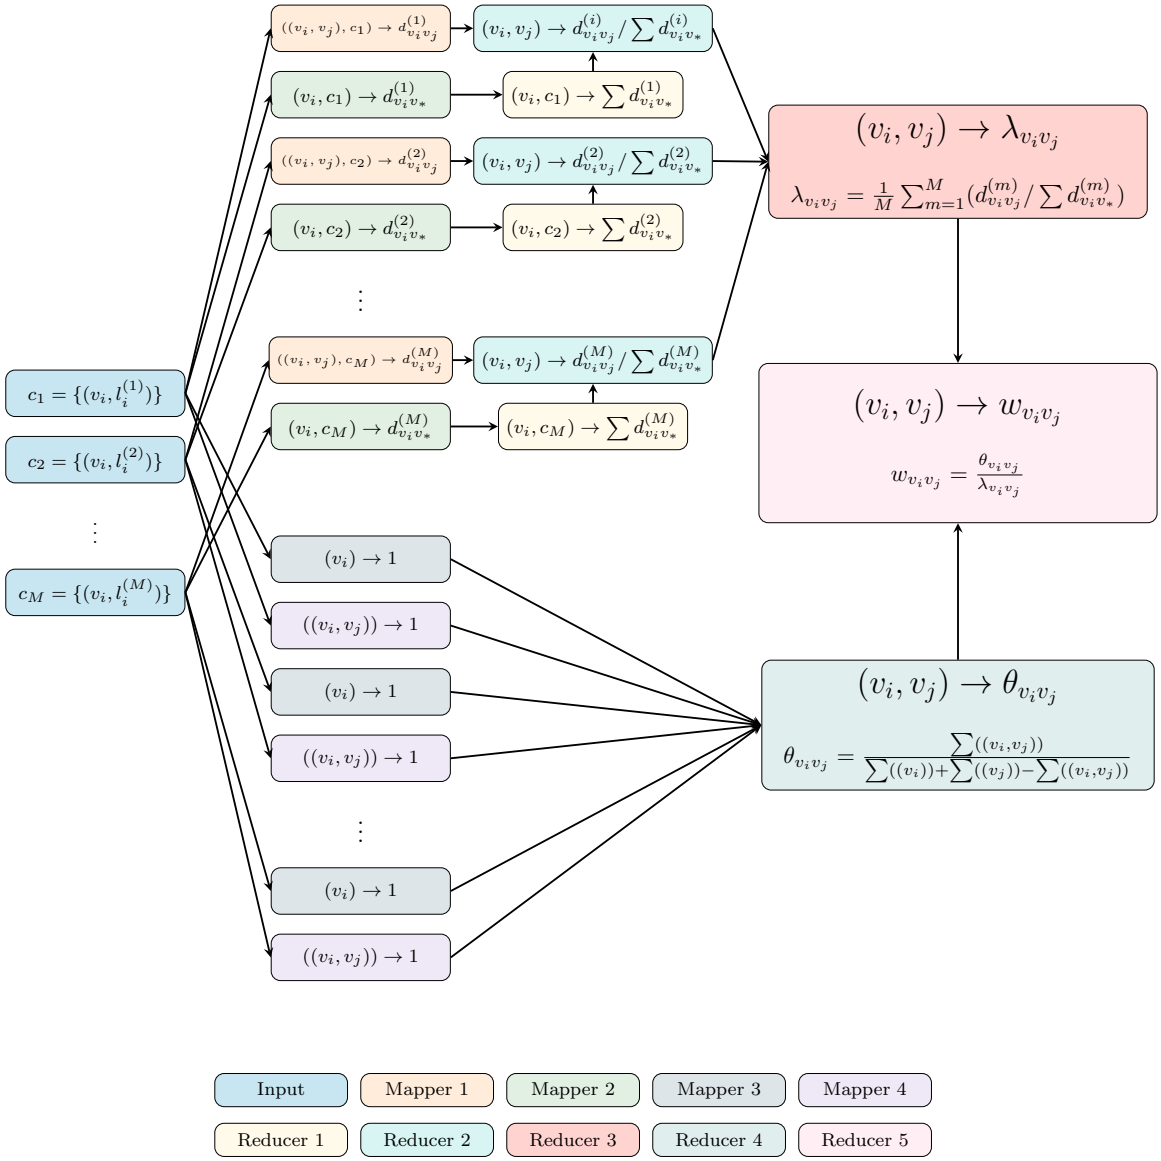

شکل ۳-۲: روش پیشنهادی در چارچوب Map-Reduce

فصل ۴

آزمون مدل

در قسمت پیش‌رو آزمایشاتی را برای بررسی روش پیشنهادی ارائه می‌دهیم تا مدل پیشنهادی را از دو منظر (۱) دقت در استنتاج صحیح شبکه زیرین و (۲) حفظ ویژگی‌های ساختاری بررسی کنیم. برای این بررسی هم از مجموعه دادگان ساختگی و هم از مجموعه دادگان حقیقی استفاده می‌کنیم تا بتوانیم عملکرد مدل را در حالات مختلف بسنجیم. برای مقایسه از تعدادی از کارهای مرتبط که شبکه را به صورت ایستا در شرایط مشابه تخمین می‌زنند استفاده می‌کنیم: (۱) NetInf، (۲) MultiTree، (۳) NetRate، (۴) DNE، (۵) PBI، (۶) KEBC، و (۷) REFINE. همچنین شایان ذکر است که پیاده‌سازی به هر دو زبان Python و C++ انجام شده است. پیاده‌سازی زبان C++ سرعت بسیار بالایی را به ارمغان می‌آورد و می‌توان از آن برای استنتاج شبکه در مجموعه دادگان بزرگ استفاده کرد. برای مقایسه از پیاده‌سازی ارائه‌شده توسط نویسندگان کارهای رقیب استفاده شده است به جز REFINE که به پیاده‌سازی آن دسترسی پیدا نکردیم و از پیاده‌سازی خودمان برای روش پیشنهادی ایشان استفاده کرده‌ایم[۱]. برای دریافت نتایج از کارهای رقیب، مطابق توضیحات نویسندگان تنظیم ابر پارامترها را برای دریافت بهترین خروجی از آن‌ها انجام دادیم.

۴-۱ معیارهای مقایسه

معیارهایی که برای بررسی عملکرد مدل‌ها استفاده می‌کنیم را می‌توانیم به سه دسته اصلی تقسیم کنیم: (۱) معیارهایی که عملکرد مدل در استنتاج گراف زیرین را می‌سنجند، (۲) معیارهایی که حفظ مشابهت ساختاری در گراف استنتاج‌شده توسط مدل نسبت به گراف اصلی را می‌سنجند و

[۱] https://github.com/AryanAhadinia/REFINE

(۳) معیارهایی که ویژگی‌های ساختاری یک شبکه را اندازه‌گیری می‌کنند. با استفاده از این دسته از معیارها و محاسبه آن‌ها بر روی گراف اصلی و گراف استنتاج‌شده می‌توانیم به نتایجی در مورد عملکرد مدل‌ها در خصوص حفظ ویژگی‌های ساختاری دست پیدا کنیم. در ادامه به تعریف این معیارها می‌پردازیم.

برای بررسی عملکرد مدل در حوزه حفظ ویژگی‌های ساختاری، از مفهوم جامعه (اجتماع) که یک مفهوم قابل لمس در حوزه علوم و شبکه‌های اجتماعی است استفاده می‌کنیم. برای تشخیص جوامع موجود در یک شبکه اجتماعی از یک الگوریتم تشخیص جامعه برای هر دو گراف اصلی و استنتاج‌شده استفاده می‌کنیم. پس از بررسی گستره‌ای از الگوریتم‌های مختلف برای این امر در نهایت به انتخاب OSLOM2 برای تشخیص جوامع رسیدیم که می‌تواند با سرعت و دقت بالا در شرایط مختلف بدون نیاز به دانش پیشین و با استفاده از حافظه حداقلی اجتماع‌های شکل گرفته در یک گراف شبکه اجتماعی را تشخیص دهد [۳۲].

برای خوانایی بهتر، اختصارات مورد استفاده در مورد این معیارها در جدول ۴-۱ آورده شده است.

جدول ۴-۱: جدول اختصارات استفاده‌شده برای معیارهای اندازه‌گیری

مخفف	شرح
F1، **MF1**، **mF1**	امتیاز F1، ماکرو F1 و میکرو F1
JS	فاصله جنسن‌ـشانون بین توزیع درجات رئوس در شبکه اصلی و استنتاج شده
NMI	اطلاعات متقابل به‌هنجار
PWF	امتیاز F1 زوج‌گرا
Δ	اختلاف نسبی
ACS	میانگین سایز جوامع
Cnd	شار
CN	تعداد رئوس متصل
ρ	چگالی
CC	متوسط ضریب خوشه‌بندی

۴-۱-۱ معیارهای بررسی صحت استنتاج

۱. امتیاز F1: از این معیار به عنوان یک معیار متداول پر استفاده در مسائل طبقه‌بندی استفاده می‌کنیم.

۲. امتیازهای میکرو F1 (mF1) و ماکرو F1 (MF1): از آنجایی که گراف شبکه اجتماعی یک گراف تنک است، از معیارهای میکرو و ماکرو F1 به عنوان معیارهایی برای مساله طبقه‌بندی در شرایط ناهمگنی طبقات استفاده می‌کنیم که به ترتیب میانگین امتیاز F1 در سطح نمونه و طبقه را محاسبه می‌کنند.

۴-۱-۲ معیارهای بررسی حفظ مشابهت ساختاری

۱. فاصله جنسن ـ شنون (JS)[۲]: فاصله جنسن ـ شنون معیاری است که فاصله دو توزیع احتمالاتی را به صورت متقارن محاسبه می‌نماید. این معیار به صورت ۴-۱ تعریف می‌شود که در آن P و Q توزیع‌های احتمالاتی هستند. مقدار این معیار بزرگ‌تر یا مساوی صفر است. صفر نمایانگر انطباق دقیق دو توزیع است و هر آنچه که مقدار این معیار بزرگ‌تر شود، نشان‌دهنده تفاوت بیش‌تر میان دو توزیع خواهد بود.

$$JS(P,Q) = \sqrt{\frac{KL(P||Q) + KL(Q||P)}{۲}} \qquad (۴-۱)$$

۲. اطلاعات متقابل به‌هنجار (NMI)[۳]: این معیار یک معیار احتمالاتی در حوزه نظریه اطلاعات است که توسط [۳۳] پیشنهاد شده است. این معیار شباهت دو مجموعه خوشه‌بندی را مقایسه می‌کند که به صورت معادله ۴-۲ تعریف می‌شود که در آن C_A و C_B دو مجموعه خوشه‌بندی هستند. N یک ماتریس $|C_A| \times |C_B|$ است که در آن درایه N_{ij} برابر تعداد اعضای مشترک خوشه iام خوشه‌بندی A و خوشه jام خوشه‌بندی B است. مقادیر $N_{i.}$، $N_{.j}$ و $N_{..}$ به ترتیب برابر جمع درایه‌های سطر i، ستون j و کل ماتریس هستند. مقدار این معیار مابین صفر و یک است که در آن یک نمایانگر انطباق کامل و صفر نشان‌دهنده بیشینه تفاوت میان خوشه‌بندی‌های انجام شده خواهد بود.

$$NMI(C_A, C_B) = \frac{-۲\sum_{i=۱}^{|C_A|}\sum_{j=۱}^{|C_B|} N_{ij}\log\left(\frac{N_{ij}N_{..}}{N_{i.}N_{.j}}\right)}{\sum_{i=۱}^{|C_A|} N_{i.}\log\left(\frac{N_{i.}}{N_{..}}\right) + \sum_{j=۱}^{|C_B|} N_{.j}\log\left(\frac{N_{.j}}{N_{..}}\right)} \qquad (۴-۲)$$

[۲] Jensen-Shannon Distance
[۳] Normalized Mutual Information

۳. امتیاز F1 زوج‌گرا(PWF)[۴]: می‌خواهیم بررسی کنیم که آیا جفت راس u و v که در شبکه زیرین در یک جامعه بوده‌اند، در شبکه استنتاج شده نیز در یک جامعه هستند یا خیر. برای این منظور از معیار امتیاز F1 زوج‌گرا (جفت‌گرا) استفاده می‌کنیم [۳۴، ۳۵]. این معیار به صورت معادله ۴-۳ تعریف می‌شود که در آن H_{G^*} و $H_{G'}$ نمایانگر مجموعه جفت‌رئوس هم‌جامعه در گراف اصلی و استنتاج‌شده هستند.

$$PW_{precision} = \frac{|H_G \cap H_{G^*}|}{|H_{G'}|}$$

$$PW_{recall} = \frac{|H_G \cap H_{G^*}|}{|H_{G*}|}$$

$$PWF = \frac{۲PW_{precision}PW_{recall}}{PW_{precision} + PW_{recall}} \qquad (۴-۳)$$

۴-۱-۳ معیارهای اندازه‌گیری شاخصه‌های ساختاری

این دسته از معیارها مستقیما مقایسه‌ای از شبکه استنتاج‌شده و شبکه اصلی بدست نمی‌دهند. بنابرین از تفاوت نسبی آن‌ها که طبق معادله ۴-۴ تعریف می‌شود برای مقایسه استفاده می‌کنیم. در این رابطه ξ_{gt} و ξ_{in} برابر مقدار معیار ξ برای شبکه اصلی و استنتاج‌شده هستند و $\Delta\xi$ تفاوت نسبی این معیار برای دو شبکه را نشان می‌دهد.

$$\Delta\xi = \frac{|\xi_{gt} - \xi_{in}|}{\xi_{gt}} \qquad (۴-۴)$$

۱. اندازه متوسط جامعه‌ها (ACS): از این معیار برای آنکه بررسی شود که آیا جامعه‌های شبکه استخراج شده توزیع مشابه شبکه اصلی دارند استفاده می‌شود [۳۶].

۲. شار (Cnd)[۵]: مطابق معادله ۴-۵ برای هر جامعه، شار برابر نسبت تعداد پیوندهای بین‌جامعه‌ای که یک سر آن‌ها در آن جامعه قرار دارند به تعداد کل یال‌هایی که دست کم یک سر آن‌ها به راس‌های آن جامعه متصل هستند است. $C_G(S)$ و $D_G(u)$ به ترتیب برابر تعداد پیوندهای با دست‌کم یک راس در جامعه S و درجه راس u در گراف G هستند.

$$C_G(S) = \frac{C_G(S)}{\sum_{u \in S} D_G(u)} \qquad (۵-۴)$$

[۴] Pairwise F1-score
[۵] Conductance

۳. تعداد راس‌های متصل (CN): در برخی از روش‌های استنتاج پیوند، برخی راس‌ها به شبکه همبند مرکزی متصل نمی‌شوند و این ممکن است به فروپاشی کل ساختار شبکه منتهی شود. بنابرین لازم است که شبکه استنتاج‌شده تا حد امکان یک گراف همبند باشد. این معیار تعداد راس‌هایی که منزوی هستند را اندازه‌گیری می‌کند.

۴. چگالی (ρ): برای هر جامعه، چگالی برابر نسبت تعداد پیوندهای آن جامعه به تعداد کل پیوندهای ممکن بین دو به دوی رئوس آن است. برای کل شبکه چگالی به صورت میانگین چگالی جامعه‌های آن محاسبه می‌شود.

۵. متوسط ضریب خوشه‌بندی (CC): ضریب خوشه‌بندی برای هر راس در یک گراف بدون جهت، برابر نسبت تعداد مثلث‌هایی که حول آن راس شکل گرفته به تعداد کل مثلث‌هایی که ممکن است با پیوند متصل به آن راس شکل بگیرند است. ضریب خوشه‌بندی به طور رسمی طبق معادله ۴-۶ تعریف می‌شود که در آن E_G مجموعه پیوندهای بدون جهت گراف G و $D_G(u)$ برابر درجه راس u در گراف است.

$$CC_G(u) = \frac{|\{\{v,t\}|\{u,v\} \in E_G \wedge \{u,t\} \in E_G\}|}{\binom{D_G(u)}{۲}} \qquad (۴-۶)$$

برای کل گراف، متوسط ضریب خوشه‌بندی با متوسط‌گیری از ضریب خوشه‌بندی تمام رئوس آن بدست می‌آید.

۴-۲ مجموعه دادگان

۴-۲-۱ دادگان ساختگی

ما از سنجه LFR پیشنهاد شده توسط [۳۷] که شبکه ساختگی با ویژگی‌های مشابه شبکه‌های حقیقی و ساختار جامعه‌بندی‌شده می‌سازد استفاده می‌کنیم. برای تولید شبکه‌ها مختلف با میزان ساختاربندی اجتماعی متفاوت از پارامتر μ استفاده می‌کنیم که مقدار آن نسبت تعداد یال‌های بین‌جامعه‌ای به تعداد کل یال‌های متصل را نشان می‌دهد. هر آنچه مقدار μ افزایش یابد، ساختار جامعه‌ای شبکه کاهش می‌یابد. ما با مقادیر μ برابر ۰/۱، ۰/۲، ۰/۳، ۰/۴ و ۰/۵، با ۱۰۰۰ راس و متوسط و بشینه درجه ۱۵ و ۵۰ پنج شبکه تولید می‌کنیم. بر روی هر یک از پنج شبکه تولید شده توسط LFR، نه مجموعه آبشار با اندازه به ترتیب ۵۰۰، ۱۰۰۰، ۳۰۰۰، ۴۰۰۰، ۵۰۰۰، ۷۰۰۰، ۱۰۰۰۰، ۱۲۰۰۰ و ۱۵۰۰۰ توسط روش [۳۸] تولید می‌کنیم. بنابرین در نهایت ۴۵ مجموعه داده ساختگی داریم که با استفاده از آن ها می‌توانیم

تاثیر میزان ساختار جامعه‌ای و تعداد آبشارهای مشاهده‌شده را بر عملکرد مدل‌های مختلف بررسی کنیم. ویژگی‌های این مجموعه دادگان در جدول ۴-۲ نوشته شده است. توجه بفرمایید که مقدار ستون $\overline{n_c}$ میانگین و انحراف از معیار طول متوسط نه مجموعه آبشار تولید شده را نمایش می‌دهد.

جدول ۴-۲: مشخصه‌های مجموعه دادگان ساختگی

نام	μ	ACS	Cnd	CC	ρ	$\overline{n_c}$
LFR1	۰/۱	۳۵/۷۱	۰/۰۵۶	۰/۲۶۷	۰/۱۹۸	۳۱/۰ ± ۰/۲
LFR2	۰/۲	۳۵/۷۱	۰/۱۱۹	۰/۱۹۰	۰/۱۷۷	۴۶/۸ ± ۰/۳
LFR3	۰/۳	۲۹/۴۱	۰/۱۸۹	۰/۱۵۸	۰/۱۹۴	۶۴/۹ ± ۰/۳
LFR4	۰/۴	۳۵/۷۱	۰/۲۵۳	۰/۰۸۶	۰/۱۴۱	۶۹/۳ ± ۰/۹
LFR5	۰/۵	۳۵/۷۱	۰/۳۴۰	۰/۰۵۱	۰/۱۱۷	۷۶/۶ ± ۰/۳

۴-۲-۲ دادگان حقیقی

ما از مجموعه دادگان حقیقی برای بررسی عملکرد مدل در دنیای حقیقی استفاده می‌کنیم. یک مجموعه داده حقیقی، داده‌ای است که ساختار شبکه و آبشارهای منتشر شده بر آن در دسترس باشد. MemeTracker پروژه‌ای است که دادگان را از مارس ۲۰۱۱ تا فوریه ۲۰۱۲ جمع‌آوری کرده است که در آن هر راس یک نمایانگر یک وب‌سایت بر خط اشتراک‌گذاری خبر و هر یال بیانگر ابر پیوند میان دو وب‌سایت است [۳۹]. از یک مجموعه داده به نام MemeTracker که زیر مجموعه‌ای از دادگان جمع‌آوری شده توسط این پروژه است استفاده کرده‌ایم. همچنین سه زیرمجموعه دیگر از این مجموعه داده با تصفیه آن بر اساس کلمات کلیدی اخبار با کلمات LinkedIn، NBA و World می‌سازیم. همچنین از یک مجموعه داده بزرگ‌تر که از روی Twitter در بازه ۲۴ مارس تا ۲۵ آوریل ۲۰۱۲ جمع‌آوری شده است استفاده می‌کنیم [۴۰]. شبکه در این مجموعه داده با توجه به رابطه «دنبال کردن» بدست می‌آید و آبشارها بر اساس فرآیند بازنشر یک برچسب در نظر گرفته می‌شوند. مشخصات این مجموعه دادگان در جدول ۴-۳ آورده شده است.

۴-۳ تحلیل آزمایشی مدل

ما از یک مطالعه داده محور برای بررسی رابطه مقداری که برای رفتار ساختاری در معادله ۳-۱۳ تخمین زده شد با ساختار جامعه‌ای شبکه استفاده می‌کنیم. برای این مطالعه از مجموعه داده LFR1

جدول ۴-۳: مشخصه‌های مجموعه دادگان حقیقی

نام	#رئوس	#پیوندها	#آبشارها	$\overline{n_c}$	ACS	Cnd	CC	ρ
LinkedIn	۱۰۳۵	۹۲۱۵۱۶۷	۲۲۹۶۳	۲٫۹۵	۱۳٫۱۰	۰٫۳۸۳	۰٫۲۷۲	۰٫۲۱۴
Meme	۴۴۵۲	۵۴۴۴۷	۱۵۹۸۲۲۵	۴٫۶۸	۶۲٫۸۴	۰٫۸۷۱	۰٫۵۸۴	۰٫۵۲۳
NBA	۲۰۵۶	۱۱۹۵۵۵۴۶	۱۴۲۷۳۷	۲٫۹۰	۲۴٫۱۸	۰٫۴۰۲	۰٫۳۱۸	۰٫۳۰۶
Twitter	۱۲۴۰۲۳	۲۱۳۸۷۵	۱۸۲۷۸۳	۲٫۲۹	۵٫۳۷	۰٫۴۷۹	۰٫۰۳۱	۰٫۰۸۹
World	۱۳۹۰	۱۰۵۴۶۰۷۱	۶۴۶۱۸	۲٫۹۳	۲۱٫۷۱	۰٫۳۴۷	۰٫۳۳۵	۰٫۲۹۸

که ساختار جامعه‌ای خوبی دارد با مشاهده ۱۰۰۰۰ آبشار استفاده می‌کنیم. در شکل ۴-۱ ابتدا ترتیب نمایه‌گذاری راس‌ها به شکلی که راس‌هایی که در یک جامعه هستند کنار هم گیرند تغییر می‌دهیم. در شکل ۴-۱آ هر سلول ij زمانی فعال است که دو راس i و j دگرنام شده در یک جامعه باشند و در نقشه حرارتی ۴-۱ب حرارت هر سلول ij نمایانگر مقدار θ_{ij} خواهد بود. در نهایت استدلال می‌کنیم که با توجه به مقدار $p - value = 0$ محاسبه شده توسط آزمون Student's t-test برای دو توزیع مقدار θ برای پیوندهای بین‌جامعه‌ای و درون‌جامعه‌ای، تفاوت این مقدار برای این دو گروه از پیوندها قابل توجه است.

پیش‌تر نشان دادیم که پیچیدگی زمانی مدل $O(MN\overline{n_c}^2)$ است. در شکل ۴-۲ زمان اجرای مدل پیشنهادی را بر حسب $MN\overline{n_c}^2$ برای مجموعه دادگان ساختگی ۴-۲آ و دادگان حقیقی ۴-۲ب رسم کرده‌ایم. روند خطی رشد زمان اجرا بر حسب $MN\overline{n_c}^2$ نشان می‌دهد که پیچیدگی زمانی محاسبه شده در پیاده‌سازی نیز قابل دست‌یابی است.

حال در نمودار ۴-۳ به بررسی تاثیر پارامتر μ و اندازه مجموعه آبشارهای مشاهده شده بر زمان اجرای مدل می‌پردازیم. همان طور که مشاهده می‌کنید با افزایش اندازه مجموعه مشاهدات، طبق انتظاری که بر حسب پیچیدگی زمانی محاسبه شده داشتیم، زمان اجرا به صورت خطی افزایش پیدا می‌کند. همچنین مشاهده می‌شود که با افزایش مقدار μ نیز زمان اجرا افزایش پیدا می‌کند. دلیل این افزایش این است که با افزایش مقدار μ ساختار جامعه‌ای شبکه محو می‌شود و آبشار می‌تواند به جای یک جامعه به سادگی در کل شبکه پیمایش کند. این موضوع باعث می‌شود که متوسط طول آبشارها $\overline{n_c}$ افزایش پیدا کند که باعث افزایش زمان اجرا خواهد شد.

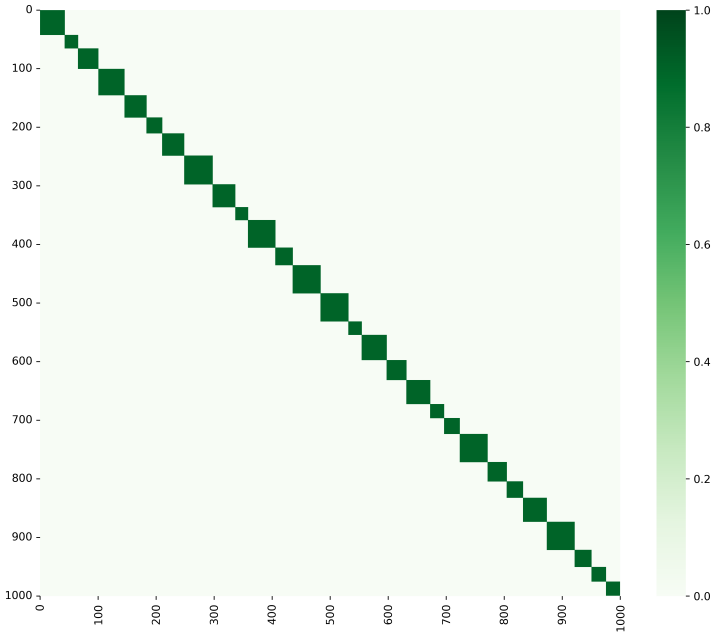

(آ) هم‌جامعگی جفت راس‌ها

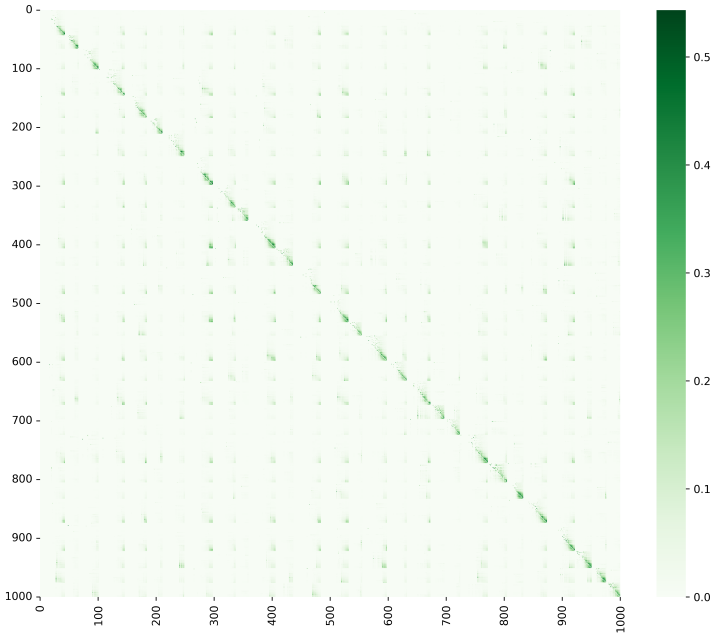

(ب) امتیاز نسبت داده شده توسط معادله ۳-۱۳

شکل ۴-۱: نقشه حرارتی نشان‌دهنده رابطه ساختار جامعه‌ای شبکه با مقدار θ

۴-۴ مقایسه نتایج

در این بخش، ما یک مقایسه کامل از عملکرد مدل پیشنهادی در مقایسه با روش‌های رقیب روی مجموعه داده‌های مصنوعی و واقعی به ترتیب در بخش‌های ۴-۴-۱ و ۴-۴-۲ ارائه می‌دهیم و در

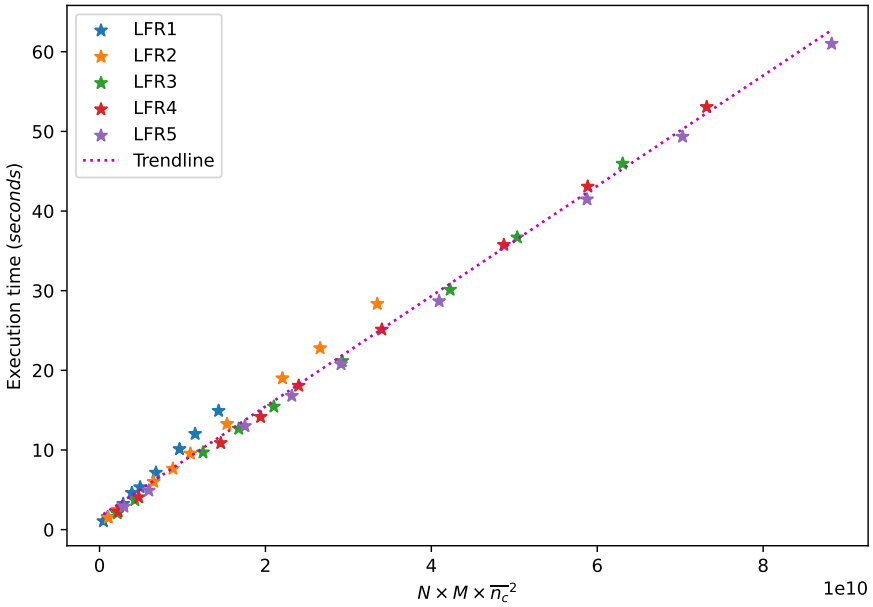

(آ) دادگان مصنوعی

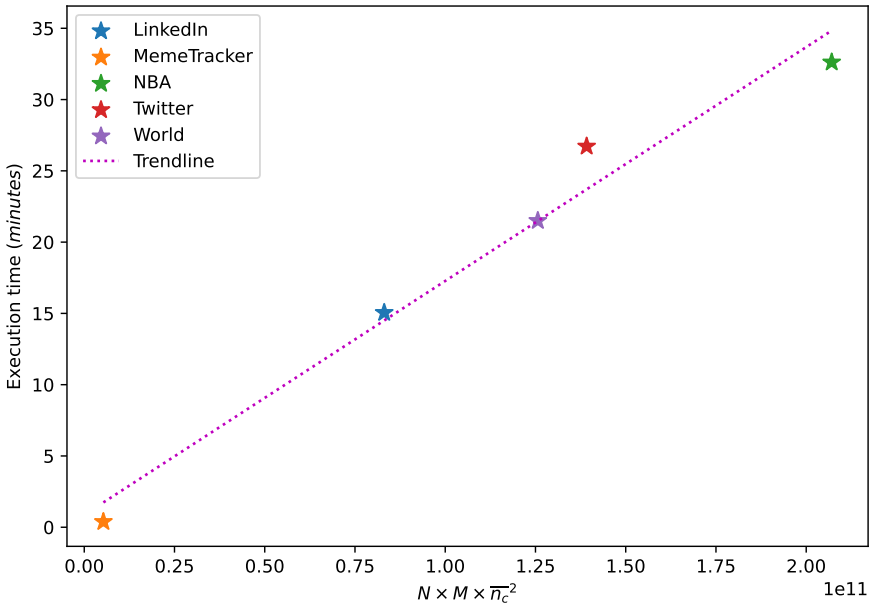

(ب) دادگان حقیقی

شکل ۴-۲: زمان اجرای مدل بر روی مجموعه دادگان ۴-۲آ مصنوعی و ۴-۲ب حقیقی

حین مقایسه عملکرد این روش‌ها، تاثیر ویژگی‌های مجموعه داده بر عملکرد این مدل‌ها را بررسی می‌کنیم.

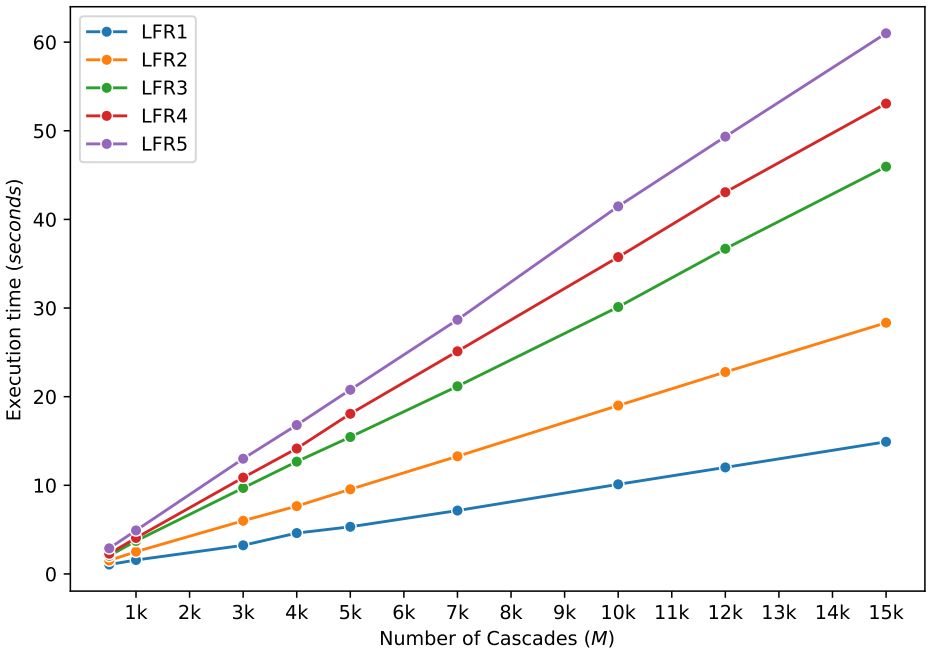

شکل ۴-۳: زمان اجرای مدل بر روی دادگان مصنوعی با مقدار μ و اندازه مشاهدات مختلف

۴-۴-۱ دادگان ساختگی

پنج شبکه ساختگی با ساختارهای مختلف جامعه‌ای در جدول ۴-۲ نشان داده شده‌اند. ما نه مجموعه آبشار بر روی هر یک از این شبکه‌ها تولید کرده‌ایم. کلیه‌ی ۴۵ مجموعه داده‌ی مصنوعی مختلف برای مقایسه و مطالعه تاثیر ساختار جامعه‌ای و تعداد آبشارهای مشاهده شده بر عملکرد مدل‌های مختلف استفاده شده‌اند.

در شکل ۴-۴، تاثیر تعداد آبشارهای مشاهده شده و ساختار جامعه‌ای بر عملکرد مدل پیشنهادی و روش‌های دیگر را بر حسب معیار F1 تجزیه و تحلیل کردیم. همانطور که نشان داده شده است، مدل پیشنهادی و NetInf نسبت به سایر روش‌ها عملکرد بهتری دارند. NetInf با کمترین تعداد آبشارهای مشاهده شده عملکرد ضعیف‌تری نسبت به مدل پیشنهادی دارد، اما زمانی که تعداد آبشارهای مشاهده شده افزایش می‌یابد کمی بهتر عمل می‌کند. مدل پیشنهادی و NetRate می‌توانند با کمترین تعداد آبشارهای مشاهده شده نسبت به سایر روش‌ها عملکرد بهتری داشته باشند، در حالی که مدل پیشنهادی با مشاهده تعداد بیشتری از آبشارها بهتر عمل می‌کند. عملکرد مدل پیشنهادی، NetInf، MultiTree و NetRate به تعداد آبشارهای مشاهده شده بستگی دارد، در حالی که عملکرد سایر مدل‌ها مستقل از تعداد آبشارهای مشاهده شده به نظر می‌رسد. عملکرد برخی از این مدل‌ها مانند مدل پیشنهادی، DNE، NetRate، KEBC و REFINE به طور مستقیم به مقدار μ که نشان‌دهنده

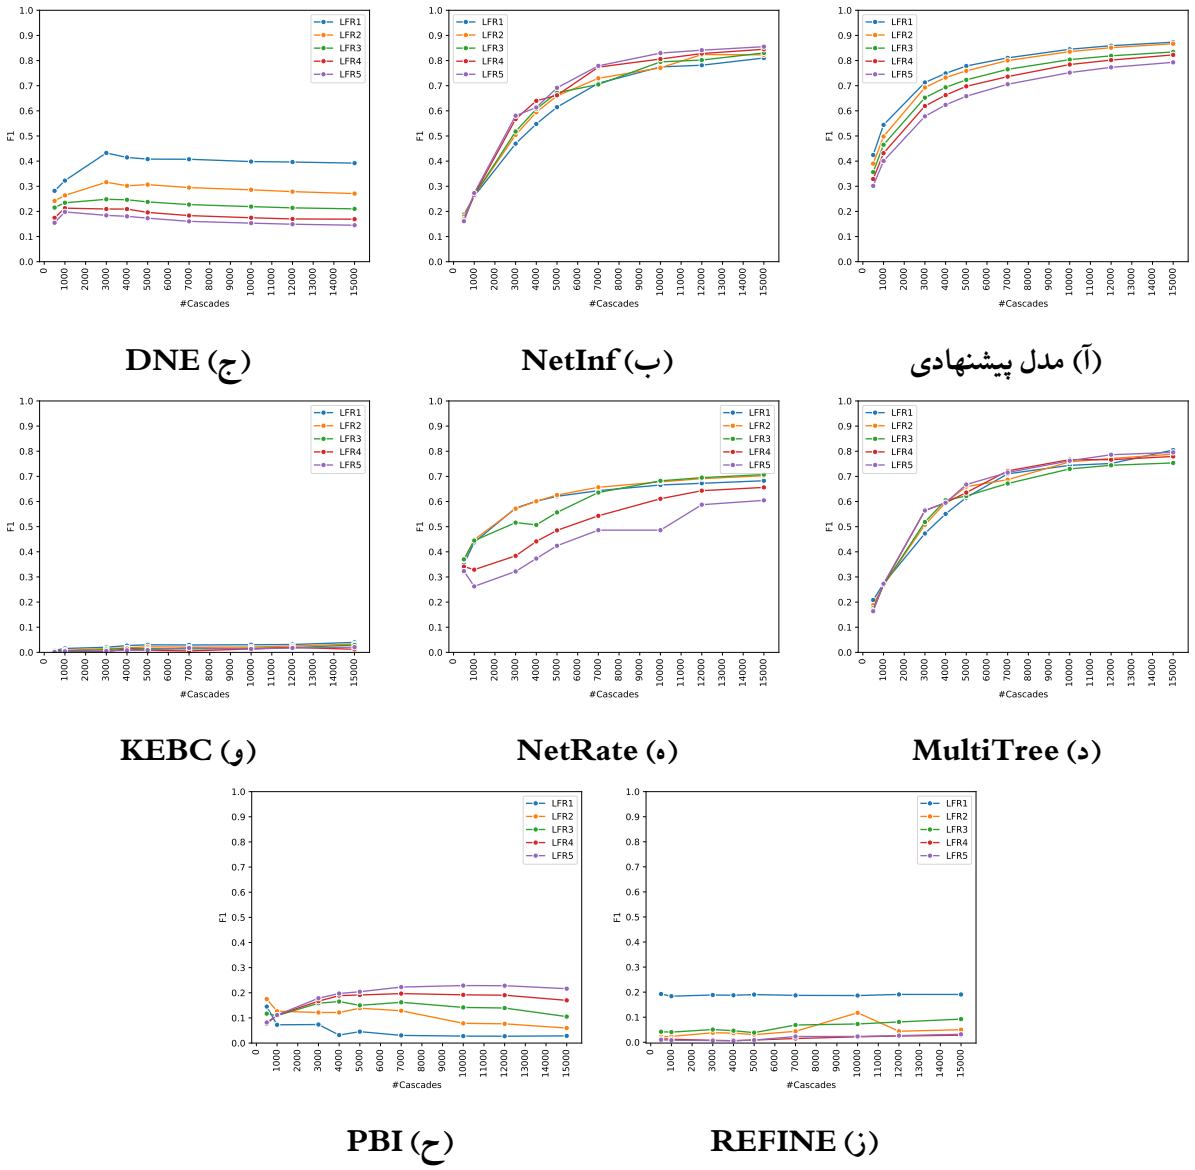

(آ) مدل پیشنهادی

(ب) NetInf

(ج) DNE

(د) MultiTree

(ه) NetRate

(و) KEBC

(ز) REFINE

(ح) PBI

شکل ۴-۴: عملکرد مدل‌های مختلف از منظر F1 بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار

درجه ساختار جامعه‌ای شبکه است وابسته است. لازم به ذکر است که عملکرد REFINE زمانی که ساختار جامعه‌ای شبکه از بین می‌رود، شدیدا کاهش می‌یابد. از آنجایی که روش‌هایی مانند NetInf و MultiTree ویژگی‌های ساختاری را در نظر نمی‌گیرند، عملکرد آنها مستقل از μ است. عملکرد PBI به طور معکوس به مقدار μ وابسته است. با افزایش مقدار μ، ساختار جامعه‌ای تا حدودی از بین می‌رود و شبکه غیر ساخت‌یافته‌تر می‌شود. KEBC به دانش پیشینی از شبکه نیاز دارد و زمانی به طور مناسب کار می‌کند که لیست محدودی از نامزدهای ممکن برای پیوندهای وجود داشته باشد. از آنجا که ما هیچ دانش اولیه‌ای نداریم، تمامی پیوندهای یک گراف کامل را به عنوان نامزد ممکن در نظر می‌گیریم، بنابراین KEBC نمی‌تواند در سیاق مساله‌ی ما به خوبی عمل کند. لازم به ذکر است که KEBC و PBI گراف‌ها را با پیوندهای بی‌جهت در نظر می‌گیرند، در حالی که سایر روش‌ها

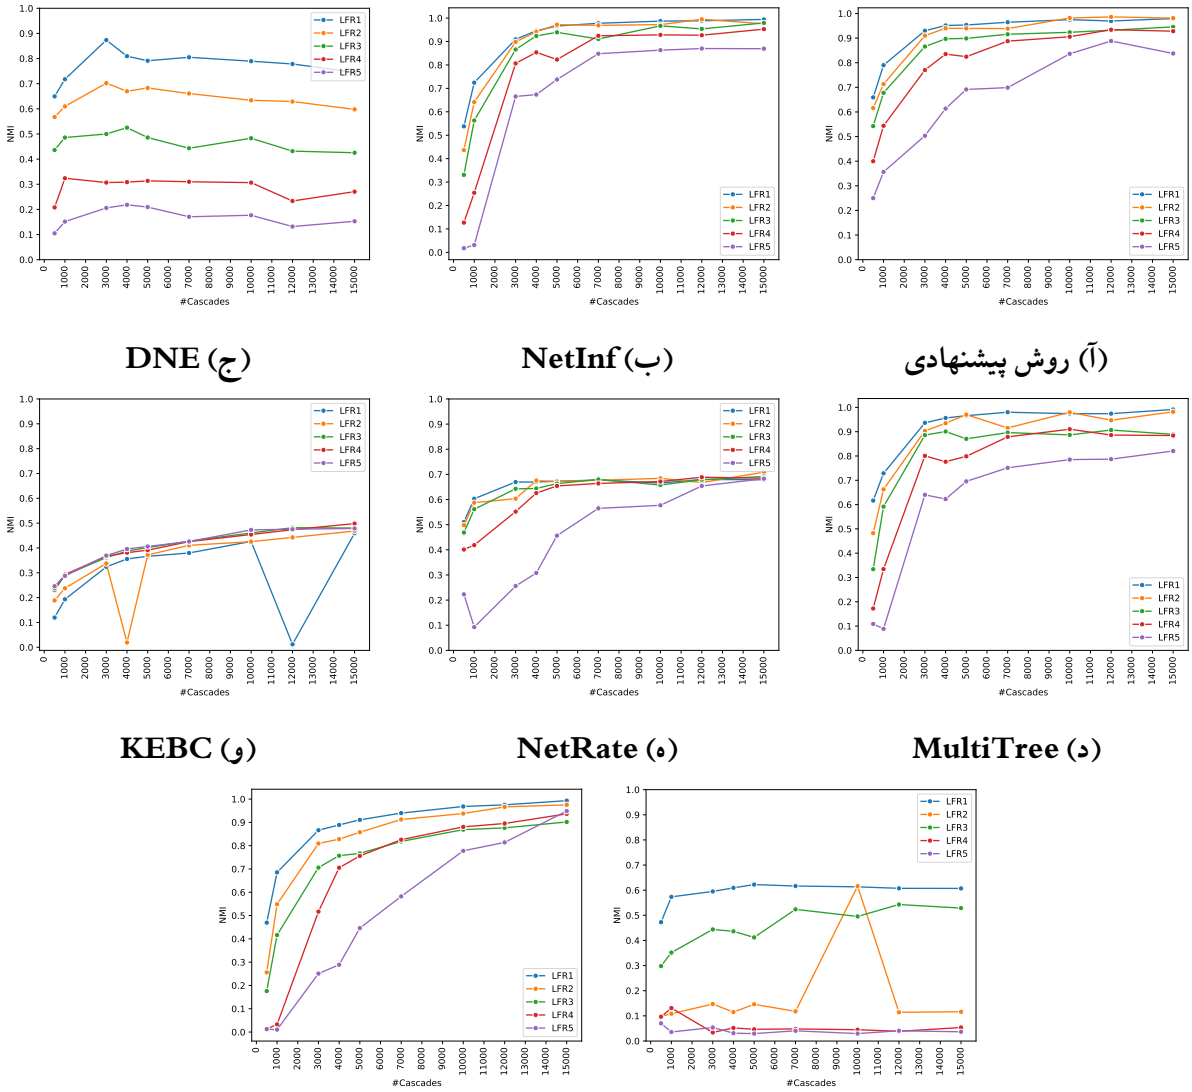

(آ) روش پیشنهادی

(ب) NetInf

(ج) DNE

(د) MultiTree

(ه) NetRate

(و) KEBC

(ز) REFINE

(ح) PBI

شکل ۴-۵: عملکرد مدل‌های مختلف از منظر NMI بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار

پیوندهای جهت‌دار را مدنظر قرار می‌دهند. این موضوع باعث کاهش عملکرد این مدل‌ها می‌شود.

مشابه مقایسه‌ای که برای F1 انجام دادیم، در شکل ۴-۵ NMI را نسبت به تعداد آبشارهای مشاهده شده و ساختار جامعه‌ای شبکه‌ها تحلیل می‌کنیم. توجه داشته باشید که ما از یک روش عامل سوم، OSLOM، برای تشخیص جوامع استفاده کرده‌ایم، بنابراین با وجود عملکرد پایین روش‌هایی مانند KEBC، REFINE و PBI در استنتاج پیوند، NMI آنها قابل قبول است زیرا NMI معیاری مستقل از گراف استنتاجی و وابسته به جامعه‌های تشخیص داده شده توسط OSLOM روی گراف استنتاجی می‌باشد. OSLOM می‌تواند با تعداد محدودی پیوند ورودی، حتی بر روی داده‌های نویزدار، جامعه‌ها را تشخیص دهد. با اینکه PBI در استنتاج پیوند عملکرد ضعیفی دارد، اما مقدار بسیار بالایی از

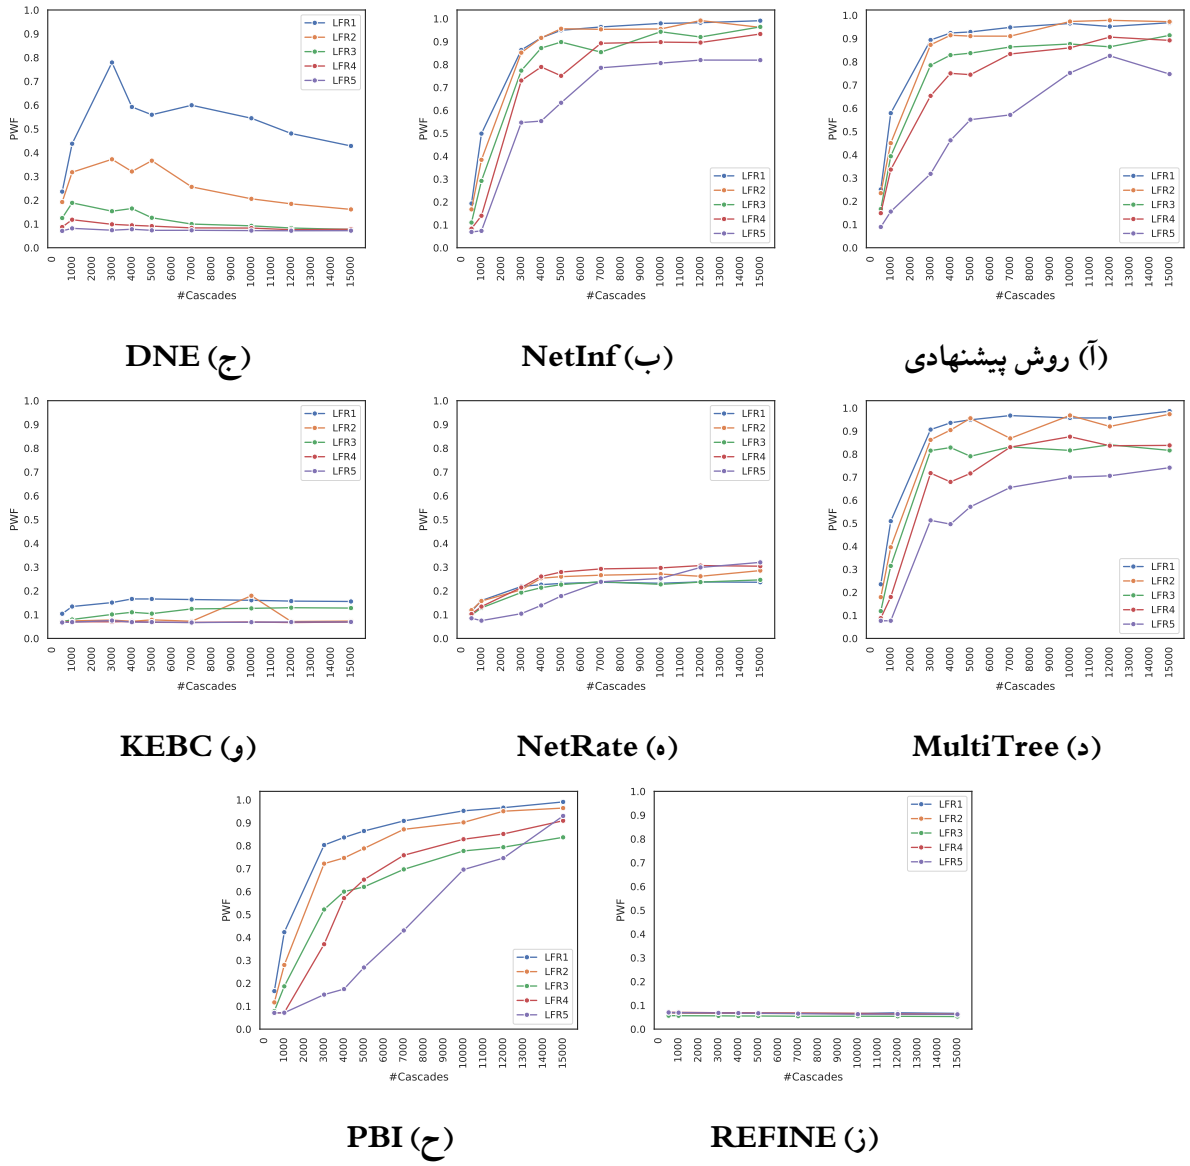

(آ) روش پیشنهادی

(ب) NetInf

(ج) DNE

(د) MultiTree

(ه) NetRate

(و) KEBC

(ز) REFINE

(ح) PBI

شکل ۴-۶: عملکرد مدل‌های مختلف از منظر PWF بر روی داده LFR1 با مشاهده ۱۰۰۰۰ آبشار

NMI را نشان می‌دهد. KEBC و REFINE نیز شرایط مشابهی دارند. این نتایج NMI بر روی مدل‌هایی با عملکرد ضعیف در استنتاج پیوند به دلیل پس‌پردازش انجام شده توسط OSLOM، جعلی هستند. بنابراین ما محدود به مطالعه روش‌هایی می‌شویم که در استنتاج پیوند با توجه به F1 عملکرد خوبی از خود نشان داده‌اند. همانطور که در اشکال ۴-۵آ، ۴-۵ب، ۴-۵ج، ۴-۵د و ۴-۵ه نشان داده شده است، هنگامی که شبکه بیشتر ساختار جامعه‌ای پیدا می‌کند، مقدار NMI افزایش می‌یابد. مقدار NMI به F1 وابسته است زیرا OSLOM زمانی می‌تواند جامعه‌ها را بهتر تشخیص دهد که شبکه استنتاجی دقیق‌تر باشد، بنابراین NMI روند مشابهی با F1 در ۴-۴ دارد.

در شکل ۴-۶، مدل‌ها را با PWF مقایسه می‌کنیم. مشابه آنچه در مورد NMI گفته شد، PWF

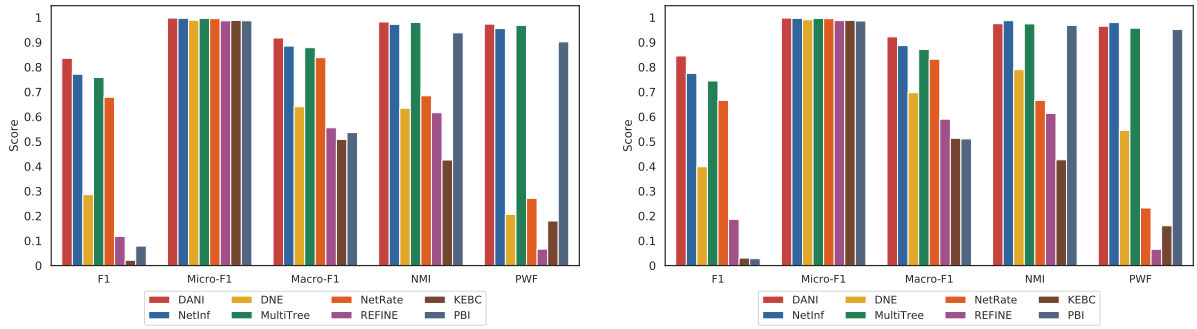

LFR1 (آ)

LFR2 (ب)

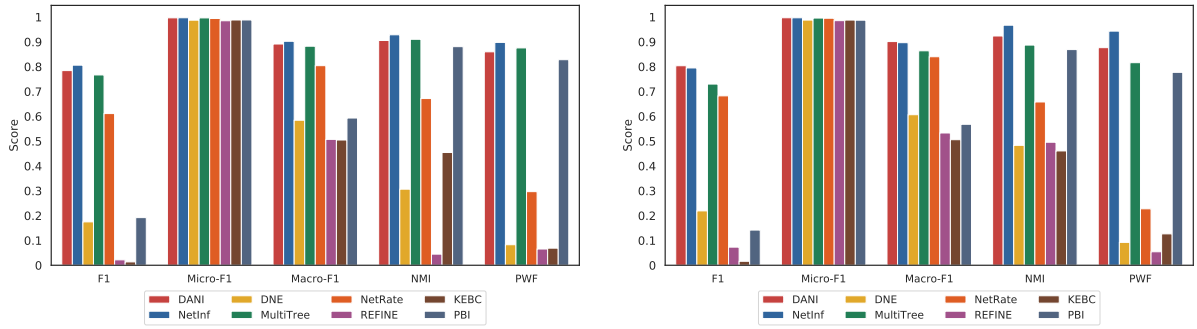

LFR3 (ج)

LFR4 (د)

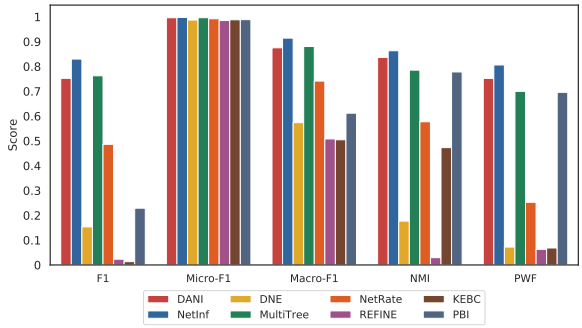

LFR5 (ه)

شکل ۴-۷: مقادیر معیارهای مختلف بر روی مجموعه دادگان ساختگی با مشاهده ۱۰۰۰۰ آبشار

معیاری است که به طور مستقیم به گراف استنتاجی وابسته نیست، بلکه از جامعه‌های تشخیص داده شده توسط OSLOM محاسبه می‌شود. بنابراین، نتایج خوب PBI از نظر PWF نیز جعلی هستند. در روش‌های دیگر به جز NetRate، PWF زمانی افزایش می‌یابد که شبکه بیشتر ساختار جامعه‌ای داشته باشد. در NetRate، در ابتدا با تعداد محدودی آبشار مشاهده شده، PWF برای شبکه‌های با ساختار جامعه‌ای بیشتر بالاتر است، اما با افزایش تعداد آبشارهای مشاهده شده، شبکه‌های با ساختار جامعه‌ای کمتر از نظر PWF بهتر می‌شوند. همانطور که در جدول ۴-۲ نشان داده شده است آبشارها در شبکه‌های با ساختار جامعه‌ای کمتر به طور میانگین بلندتر هستند، بنابراین می‌توان تحلیل بقا قوی‌تری انجام داد و احتمال تشخیص صحیح جامعه‌ها افزایش می‌یابد. همانطور که نشان داده

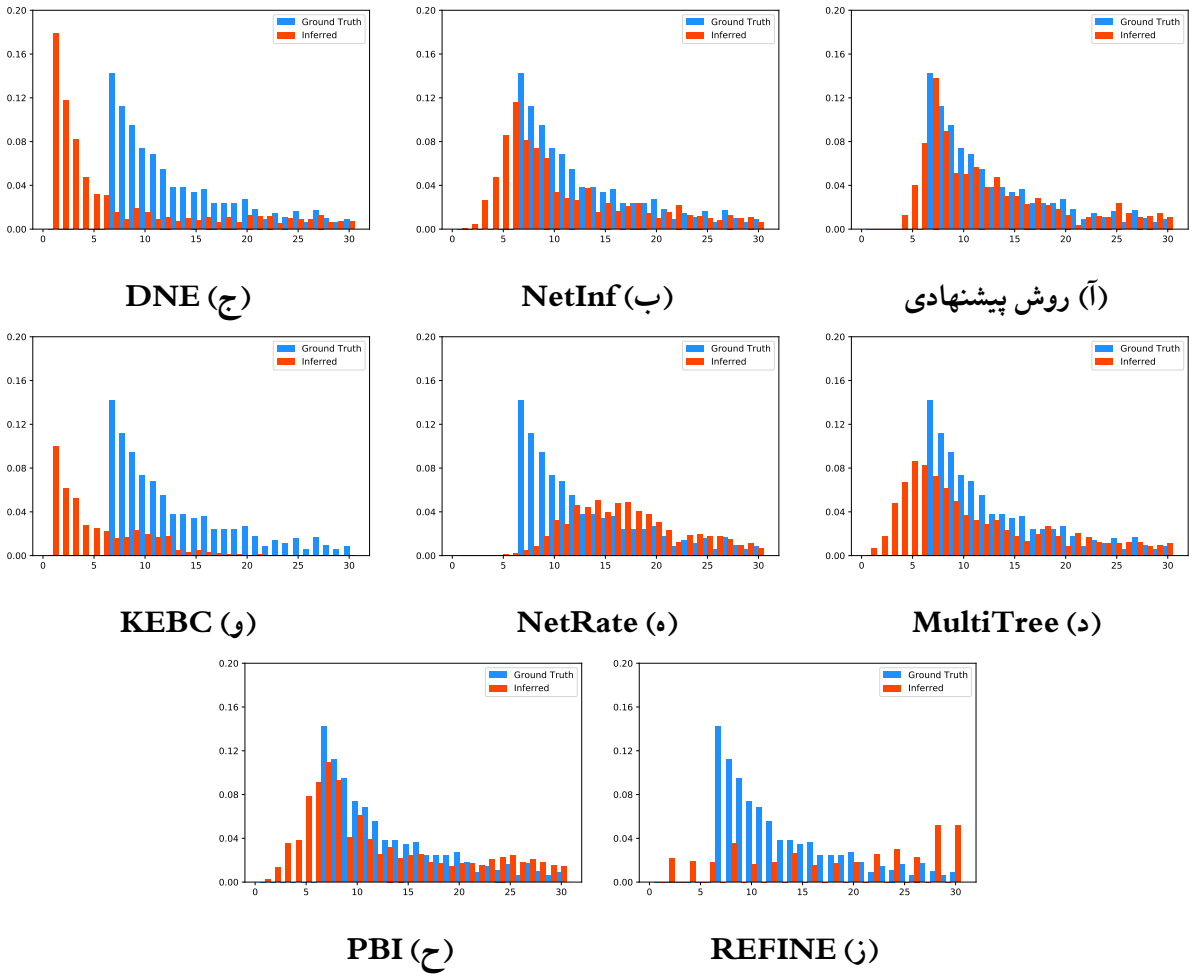

شکل ۴-۸: توزیع درجات رئوس در شبکه اصلی و شبکه استنتاج شده در مجموعه داده LFR1 با مشاهده ۱۰۰۰۰ آبشار

شده است، عملکرد سایر مدل‌ها متناسب با عملکرد آنها در استنتاج پیوند است. مدل پیشنهادی، MultiTree و NetInf بهترین عملکردها را دارند. این در حالی است که مدل پیشنهادی بر خلاف دو مدل دیگر با تعداد مشاهدات محدود نیز عملکرد قوی خود را حفظ می‌کند.

پیش‌تر، ما تاثیر تعداد آبشارهای مشاهده شده بر عملکرد مدل‌ها را بررسی کردیم. دیدیم که با افزایش تعداد آبشارها، معیارها برای اکثر مدل‌ها به یک مقدار خاص همگرا می‌شوند و افزایش بیشتر آن، تغییر چشم‌گیری در عملکرد مدل‌ها ایجاد نمی‌کند. از این پس، در مقایسه عملکرد مدل‌ها بر روی مجموعه‌های داده مصنوعی، ما بر مجموعه‌های داده با مجموعه‌های مشاهده به اندازه ۱۰۰۰۰ آبشار تمرکز خواهیم کرد.

توزیع درجات راس‌ها می‌تواند شباهت بین شبکه اصلی و استنتاج‌شده را نشان دهد. ما از فاصله جنسن ـ شنون در جدول ۴-۴ استفاده کردیم تا شباهت دو توزیع را اندازه‌گیری کنیم. در شکل ۴-۸،

جدول ۴-۴: نتایج روش پیشنهادی و سایر روش‌های رقیب بر روی مجموعه دادگان ساختگی

	روش	F1	MF1	mF1	JS	NMI	PWF	ΔACS	ΔCnd	ΔCN	$\Delta\rho$	ΔCC
LFR1	روش پیشنهادی	۰/۸۴	۰/۹۲	۰/۹۹۸	۰/۲۷	۰/۹۷	۰/۹۶	۰/۰۰	۰/۴۳	۰/۰۰	۰/۰۱	۰/۳۲
	NetInf	۰/۷۷	۰/۸۹	۰/۹۹۷	۰/۳۸	۰/۹۹	۰/۹۸	۰/۰۰	۰/۸۰	۰/۰۰	۰/۰۷	۰/۳۳
	DNE	۰/۴۰	۰/۷۰	۰/۹۹۱	۰/۶۲	۰/۷۹	۰/۵۴	۰/۱۷	۴/۷۱	۰/۱۵	۰/۲۳	۰/۶۴
	MultiTree	۰/۷۴	۰/۸۷	۰/۹۹۶	۰/۴	۰/۹۷	۰/۹۶	۰/۰۰	۱/۰۰	۰/۰۰	۰/۰۹	۰/۲۷
	NetRate	۰/۶۷	۰/۸۳	۰/۹۹۵	۰/۴۸	۰/۶۷	۰/۲۳	۰/۰۰	۱/۴۴	۰/۳۲	۰/۴۳	۰/۰۴
	REFINE	۰/۱۹	۰/۵۹	۰/۹۸۷	۰/۶۶	۰/۶۱	۰/۰۷	۰/۰۳	۰/۳۵	۰/۴۰	۲/۰۸	۲/۱۵
	KEBC	۰/۰۳	۰/۵۱	۰/۹۸۸	۰/۷۲	۰/۴۳	۰/۱۶	۰/۹۳	۱۵/۹۹	۰/۵۸	۱/۰۰	۰/۹۵
	PBI	۰/۰۳	۰/۵۱	۰/۹۸۶	۰/۳۷	۰/۹۷	۰/۹۵	۰/۰۰	۱/۰۷	۰/۰۰	۰/۲۵	۰/۳۳
LFR2	روش پیشنهادی	۰/۸۴	۰/۹۲	۰/۹۸۲	۰/۲۴	۰/۹۸	۰/۹۷	۰/۰۳	۰/۲۸	۰/۰۰	۰/۱۰	۰/۳۰
	NetInf	۰/۷۷	۰/۸۸	۰/۹۷۲	۰/۳۹	۰/۹۷	۰/۹۶	۰/۰۰	۰/۶۰	۰/۰۰	۰/۱۵	۰/۱۰
	DNE	۰/۲۹	۰/۶۴	۰/۶۳۴	۰/۶۷	۰/۶۳	۰/۲۱	۰/۲۶	۲/۷۳	۰/۳۴	۰/۰۳	۰/۹۹
	MultiTree	۰/۷۶	۰/۸۸	۰/۹۸۰	۰/۴۰	۰/۹۸	۰/۹۷	۰/۰۰	۰/۵۷	۰/۰۰	۰/۱۵	۰/۱۰
	NetRate	۰/۶۸	۰/۸۴	۰/۶۸۴	۰/۴۸	۰/۶۸	۰/۲۷	۰/۰۰	۰/۸۳	۰/۲۹	۰/۴۷	۰/۰۶
	REFINE	۰/۱۲	۰/۵۶	۰/۶۱۶	۰/۶۴	۰/۶۲	۰/۰۷	۰/۰۰	۰/۴۶	۰/۳۷	۱/۷۷	۳/۰۰
	KEBC	۰/۰۲	۰/۵۱	۰/۴۲۵	۰/۷۰	۰/۴۳	۰/۱۸	۰/۹۳	۷/۱۴	۰/۵۸	۱/۰۰	۰/۹۶
	PBI	۰/۰۸	۰/۵۴	۰/۹۳۸	۰/۳۹	۰/۹۴	۰/۹۰	۰/۰۳	۰/۵۴	۰/۰۰	۰/۲۴	۰/۴۱
LFR3	روش پیشنهادی	۰/۸۰	۰/۹۰	۰/۹۹۷	۰/۲۶	۰/۹۲	۰/۸۸	۰/۰۳	۰/۲۵	۰/۰۰	۰/۰۳	۰/۲۴
	NetInf	۰/۷۹	۰/۹۰	۰/۹۹۷	۰/۳۶	۰/۹۷	۰/۹۴	۰/۰۰	۰/۳۳	۰/۰۰	۰/۱۵	۰/۰۴
	DNE	۰/۲۲	۰/۶۱	۰/۹۸۸	۰/۷۰	۰/۴۸	۰/۰۹	۰/۳۳	۱/۶۵	۰/۴۶	۰/۰۸	۱/۲۱
	MultiTree	۰/۷۳	۰/۸۶	۰/۹۹۶	۰/۴۱	۰/۸۹	۰/۸۲	۰/۰۳	۰/۴۷	۰/۰۱	۰/۲۵	۰/۰۶
	NetRate	۰/۶۸	۰/۸۴	۰/۹۹۵	۰/۵۱	۰/۶۶	۰/۲۳	۰/۰۳	۰/۷۹	۰/۲۸	۰/۳۹	۰/۱۵
	REFINE	۰/۰۷	۰/۵۳	۰/۹۸۵	۰/۶۲	۰/۵۰	۰/۰۵	۰/۰۳	۰/۲۴	۰/۳۰	۱/۳۹	۳/۳۰
	KEBC	۰/۰۲	۰/۵۱	۰/۹۸۸	۰/۶۸	۰/۴۶	۰/۱۳	۰/۹۲	۴/۲۸	۰/۵۴	۱/۰۰	۰/۹۴
	PBI	۰/۱۴	۰/۵۷	۰/۹۸۷	۰/۴۱	۰/۸۷	۰/۷۸	۰/۰۰	۰/۲۴	۰/۰۰	۰/۳۱	۰/۴۶
LFR4	روش پیشنهادی	۰/۷۸	۰/۸۹	۰/۹۹۷	۰/۲۷	۰/۹۱	۰/۸۶	۰/۰۳	۰/۲۹	۰/۰۰	۰/۰۳	۰/۳۳
	NetInf	۰/۸۱	۰/۹۰	۰/۹۹۷	۰/۳۵	۰/۹۳	۰/۹۰	۰/۰۰	۰/۳۱	۰/۰۰	۰/۱۷	۰/۰۰
	DNE	۰/۱۷	۰/۵۸	۰/۹۸۷	۰/۷۳	۰/۳۱	۰/۰۸	۰/۰۹	۱/۳۸	۰/۵۷	۰/۰۱	۳/۷۹
	MultiTree	۰/۷۷	۰/۸۸	۰/۹۹۶	۰/۳۸	۰/۹۱	۰/۸۸	۰/۰۰	۰/۳۳	۰/۰۱	۰/۲۱	۰/۰۲
	NetRate	۰/۶۱	۰/۸۰	۰/۹۹۴	۰/۵۳	۰/۶۷	۰/۳۰	۰/۰۰	۰/۶۰	۰/۲۶	۰/۳۰	۰/۲۲
	REFINE	۰/۰۲	۰/۵۱	۰/۹۸۵	۰/۷۵	۰/۰۴	۰/۰۷	۴/۸۰	۰/۴۶	۰/۴۲	۰/۱۶	۷/۷۲
	KEBC	۰/۰۱	۰/۵۰	۰/۹۸۸	۰/۷۰	۰/۴۵	۰/۰۷	۰/۹۴	۲/۸۶	۰/۵۳	۱/۰۰	۰/۹۳
	PBI	۰/۱۹	۰/۵۹	۰/۹۸۸	۰/۳۹	۰/۸۸	۰/۸۳	۰/۰۰	۰/۲۵	۰/۰۰	۰/۲۸	۰/۴۹
LFR5	روش پیشنهادی	۰/۷۵	۰/۸۸	۰/۹۹۶	۰/۲۷	۰/۸۴	۰/۷۵	۰/۰۳	۰/۲۷	۰/۰۰	۰/۰۶	۰/۵۷
	NetInf	۰/۸۳	۰/۹۱	۰/۹۹۷	۰/۳۴	۰/۸۶	۰/۸۱	۰/۰۰	۰/۲۰	۰/۰۰	۰/۲۱	۰/۱۲
	DNE	۰/۱۵	۰/۵۷	۰/۹۸۷	۰/۷۵	۰/۱۸	۰/۰۷	۰/۱۹	۰/۶۷	۰/۶۲	۰/۲۳	۶/۶۵
	MultiTree	۰/۷۶	۰/۸۸	۰/۹۹۶	۰/۴۰	۰/۷۹	۰/۷۰	۰/۰۰	۰/۲۹	۰/۰۱	۰/۲۱	۰/۱۰
	NetRate	۰/۴۹	۰/۷۴	۰/۹۹۲	۰/۴۸	۰/۵۸	۰/۲۵	۰/۰۷	۰/۶۳	۰/۲۵	۰/۰۷	۰/۳۱
	REFINE	۰/۰۲	۰/۵۱	۰/۹۸۵	۰/۷۳	۰/۰۳	۰/۰۶	۶/۲۵	۰/۰۹	۰/۵۰	۰/۶۶	۱۶/۷۲
	KEBC	۰/۰۱	۰/۵۰	۰/۹۸۸	۰/۷۰	۰/۴۷	۰/۰۷	۰/۹۴	۱/۸۸	۰/۴۸	۱/۰۰	۰/۸۷
	PBI	۰/۲۳	۰/۶۱	۰/۹۸۹	۰/۳۵	۰/۷۸	۰/۷۰	۰/۰۰	۰/۱۸	۰/۰۰	۰/۳۲	۰/۴۷

توزیع آماری درجات گره‌ها برای LFR1 با ۱۰۰۰۰ آبشار مشاهده شده نشان داده شده است. همانطور که دیده می‌شود، توزیع درجات راس‌های شبکه استنتاجی توسط روش پیشنهادی بیشترین شباهت با شبکه اصلی را دارد. توزیع روش‌هایی مانند DNE و KEBC به صفر متمایل می‌شوند، در حالی که روش‌های مانند NetInf، MultiTree، NetRate و PBI به توزیع‌های ملایم‌تر و طبیعی‌تر متمایل هستند. از آنجا که عملکرد REFINE در استنتاج پیوند ضعیف است، توزیع درجات آن معنی‌دار نخواهد بود.

در شکل ۴-۷ و جدول ۴-۴، ما یک مطالعه جامع در مورد عملکرد مدل‌ها روی مجموعه‌های داده مصنوعی با مشاهده ۱۰۰۰۰ آبشار انجام داده‌ایم. در مساله استنتاج پیوند با توجه به معیارهایی که در ۴-۱ تعریف شده‌اند، مدل پیشنهادی نسبت به سایر مدل‌ها در LFR1، LFR2 و LFR3 که در آنها شبکه‌ها مولفه‌ای‌تر هستند، عملکرد بهتری دارد، در حالی که NetInf در LFR4 و LFR5 که در آنها شبکه به شبکه تصادفی نزدیک‌تر می‌شود و ساختار مولفه‌ای به تدریج از بین می‌رود، عملکرد بهتری نشان می‌دهد چرا که NetInf به ساختار شبکه زیرین حساسیت ندارد. همانطور که پیش‌تر بحث شد، ما از فاصله جنسن‌ـشانون برای مقایسه تفاوت در توزیع درجات گره‌ها در شبکه اصلی و شبکه استنتاجی استفاده کردیم. در همه مجموعه‌های داده، مدل پیشنهادی کمترین فاصله را دارد. در معیارهای دیگری مانند NMI، PWF، ΔACS، ΔCnd، ΔCN، $\Delta\rho$ و ΔCC، در اکثر آنها، مدل پیشنهادی یکی از بهترین مدل‌هاست. توجه داشته باشید که در این دسته از معیارها، نتایج روش‌هایی با عملکرد ضعیف در استنتاج پیوند قابل قبول نیستند زیرا توانایی‌های OSLOM ممکن است باعث پوشانده شدن عملکرد ضعیف مدل و تولید مقادیر جعلی شود.

۴-۴-۲ دادگان حقیقی

ما مدل‌ها را بر روی مجموعه داده‌های واقعی موجود ارزیابی کردیم. لازم به ذکر است که NetRate، PBI و KEBC نتوانستند در طی ۷۲ ساعت بر روی این مجموعه داده‌ها پایان یابند، بنابراین نتایج آن‌ها در این بخش گزارش نشده است. از آن‌جا که REFINE برای اجرا به ماتریس‌های $N \times N$ نیاز دارد و توییتر بیشترین تعداد گره‌ها ($N = ۱۲۴k$) را در میان مجموعه داده‌های حقیقی دارد، نتایج REFINE برای مجموعه داده توییتر موجود نمی‌باشد. جدول ۴-۵ رفتار روش‌ها در مجموعه داده‌های واقعی را نمایش می‌دهد.

LinkedIn دارای تعداد زیادی آبشار مشاهده‌شده و تعداد کمی پیوند است. در این شرایط، روش پیشنهادی عملکرد خوبی دارد. در تمام معیارها، روش پیشنهادی عملکرد بهتری نسبت به سایر

جدول ۴-۵: نتایج روش پیشنهادی و سایر روش‌های رقیب بر روی مجموعه دادگان حقیقی

	روش	F1	MF1	mF1	JS	NMI	PWF	ΔACS	ΔCnd	ΔCN	$\Delta\rho$	ΔCC
LinkedIn	روش پیشنهادی	۰/۳۳	۰/۶۷	۰/۹۹	۰/۳۰	۰/۶۱	۰/۲۳	۰/۰۹	۰/۲۴	۰/۰۰	۱/۴۵	۰/۶۲
	NetInf	۰/۳۰	۰/۶۵	۰/۹۸	۰/۳۰	۰/۶۰	۰/۳۰	۰/۲۶	۰/۵۹	۰/۰۵	۱/۲۴	۰/۹۱
	DNE	۰/۳۲	۰/۶۶	۰/۹۸	۰/۳۰	۰/۵۶	۰/۲۵	۰/۱۳	۰/۵۲	۰/۱۶	۱/۴۹	۱/۰۷
	MultiTree	۰/۳۰	۰/۶۵	۰/۹۸	۰/۳۰	۰/۵۹	۰/۳۱	۰/۳۲	۰/۶۲	۰/۰۶	۱/۲۶	۰/۹۱
	REFINE	۰/۲۹	۰/۶۳	۰/۹۸	۰/۷۰	۰/۳۸	۰/۱۴	۲/۷۶	۰/۸۴	۰/۶۴	۲/۶۸	۲/۱۹
Meme	روش پیشنهادی	۰/۹۹	۰/۹۹	۰/۹۹	۰/۴۰	۰/۶۸	۰/۹۳	۰/۱۶	۰/۰۱	۰/۰۰	۰/۰۸	۰/۰۱
	NetInf	۰/۱۱	۰/۵۳	۰/۹۲	۰/۵۷	۰/۵۱	۰/۸۹	۰/۱۳	۰/۳۷	۰/۰۱	۰/۶۸	۰/۶۹
	DNE	۰/۹۹	۰/۹۹	۰/۹۸	۰/۴۰	۰/۶۰	۰/۹۲	۰/۱۷	۰/۰۲	۰/۰۱	۰/۱۵	۰/۰۱
	MultiTree	۰/۱۱	۰/۵۳	۰/۹۲	۰/۵۷	۰/۵۰	۰/۹۰	۰/۰۸	۰/۳۴	۰/۰۱	۰/۶۸	۰/۶۹
	REFINE	۰/۰۶	۰/۴۸	۰/۸۴	۰/۷۷	۰/۲۲	۰/۴۱	۱/۵۰	۰/۰۵	۰/۴۷	۰/۲۴	۰/۰۲
NBA	روش پیشنهادی	۰/۳۹	۰/۷۰	۰/۹۸	۰/۳۰	۰/۶۴	۰/۲۹	۰/۱۷	۰/۲۳	۰/۰۰	۰/۸۶	۰/۳۴
	NetInf	۰/۳۹	۰/۷۰	۰/۹۸	۰/۳۰	۰/۶۳	۰۳۱	۰/۰۷	۰/۱۴	۰/۰۳	۰/۶۴	۰/۶۰
	DNE	۰/۴۱	۰/۷۰	۰/۹۸	۰/۲۹	۰/۶۳	۰/۳۰	۰/۱۸	۰/۰۸	۰/۰۵	۰/۸۱	۰/۹۳
	MultiTree	۰/۳۹	۰/۷۰	۰/۹۸	۰/۳۰	۰/۶۴	۰/۳۳	۰/۱۱	۰/۱۰	۰/۰۳	۰/۶۶	۰/۶۰
	REFINE	۰/۰۱	۰/۴۹	۰/۹۶	۰/۷۰	۰/۲۳	۰/۰۸	۰/۸۵	۱/۱۴	۰/۶۵	۰/۲۵	۰/۲۷
Twitter	روش پیشنهادی	۰/۴۰	۰/۷۰	۰/۹۹	۰/۱۰	۰/۸۸	۰/۱۶	۰/۰۵	۰/۰۵	۰/۰۰	۱/۱۲	۰/۴۶
	NetInf	۰/۰۱	۰/۵۰	۰/۹۹	۰/۷۵	۰/۱۱	۰/۰۱	۵/۷۱	۰/۹۸	۰/۹۲	۳/۹۷	۰/۷۸
	DNE	۰/۳۵	۰/۶۷	۰/۹۹	۰/۱۰	۰/۸۵	۰/۲۱	۰/۱۳	۰/۰۴	۰/۰۲	۱/۳۰	۰/۵۷
	MultiTree	۰/۰۱	۰/۵۰	۰/۹۹	۰/۷۵	۰/۱۱	۰/۰۱	۵/۷۳	۰/۹۹	۰/۹۳	۳/۹۸	۰/۷۸
	REFINE	–	–	–	–	–	–	–	–	–	–	–
World	روش پیشنهادی	۰/۴۰	۰/۷۰	۰/۹۸	۰/۴۰	۰/۶۳	۰/۲۷	۰/۱۶	۰/۰۵	۰/۰۰	۰/۹۷	۰/۴۳
	NetInf	۰/۳۰	۰/۶۵	۰/۹۷	۰/۳۷	۰/۶۱	۰/۲۸	۰/۰۵	۰/۲۴	۰/۰۳	۰/۶۵	۰/۵۷
	DNE	۰/۳۹	۰/۶۹	۰/۹۸	۰/۳۵	۰/۶۱	۰/۲۸	۰/۱۷	۰/۲۱	۰/۰۵	۰/۶۸	۰/۸۱
	MultiTree	۰/۳۰	۰/۶۵	۰/۹۷	۰/۳۷	۰/۶۱	۰/۳۱	۰/۰۳	۰/۲۶	۰/۰۳	۰/۶۳	۰/۵۶
	REFINE	۰/۰۱	۰/۴۹	۰/۴۹	۰/۷۰	۰/۲۵	۰/۱۳	۱/۰۰	۱/۳۵	۰/۶۶	۰/۳۰	۰/۱۹

روش‌ها دارد به جز در PWF و $\Delta\rho$ که نتایج با DNE قابل مقایسه است. روش‌های دیگر نیز در این مجموعه داده نیز عملکرد خوبی از خود نشان می‌دهند چرا که تعداد کافی آبشار مشاهده‌شده برای استنتاج پیوندهایی که در این شبکه شکل گرفته‌اند، وجود دارد.

مجموعه داده MemeTracker چگال‌ترین مجموعه داده با تعداد کمتری آبشار است. از آنجا که عملکرد NetInf و MultiTree به اندازه‌ی مشاهدات حساس است، این روش‌ها نمی‌توانند در این مجموعه داده به خوبی عمل کنند. عملکرد ضعیف REFINE در این مجموعه داده و نتایج آن در معیارهای وابسته به جوامع کشف شده توسط OSLOM بی‌معنی است. نتایج DNE قابل قبول هستند، اما روش پیشنهادی عملکرد بهتری از نظر تمام معیارها دارد.

NBA دارای تعداد زیادی آبشار مشاهده‌شده است و تعداد نسبتاً زیادی پیوند است که باید استنتاج شود. عملکرد REFINE در این مجموعه داده ضعیف است. نتایج چهار روش دیگر به طور کلی

به یکدیگر نزدیک هستند، اما DNE عملکرد بهتری از نظر استنتاج پیوند دارد و از نظر معیارهای مشخصه‌های ساختاری، با بهترین نتایج قابل مقایسه است. روش پیشنهادی ما تنها روش در این آزمایش است که راس‌های منزوی تولید نمی‌کند.

توییتر بزرگترین مجموعه داده ما با تنک‌ترین توزیع است. روش پیشنهادی در این مجموعه داده در تمام معیارها بهترین عملکرد را دارد به جز در PWF و ΔCnd که نتایج روش پیشنهادی به DNE نزدیک است. عملکرد ضعیف NetInf و MultiTree در توییتر نشان‌دهنده این است که این روش‌ها نمی‌توانند در مجموعه داده‌های تنک به خوبی عمل کنند.

در نهایت، مجموعه داده World، به جز این‌که تعداد متوسطی از آبشارهای مشاهده‌شده دارد مشابه LinkedIn و NBA است،. روش پیشنهادی در بیشتر معیارها بهترین عملکرد را دارد. بر روی این مجموعه داده REINE علی‌الرغم عملکرد ضعیفی که در مساله استنتاج گراف دارد، ضریب خوشه‌بندی نزدیک‌تری به شبکه اصلی از خود نشان می‌دهد.

۵-۴ جمع‌بندی

در این قسمت با بررسی مدل و کارهای رقیب بر روی گستره‌ای از مجموعه دادگان متنوع حقیقی و ساختگی، با استفاده از معیارهای متنوعی عملکرد آن‌ها را با یک‌دیگر مقایسه کردیم. همچنین به صورت عملی زمان اجرای مدل را به همراه رویکرد آن نسبت به حفظ مشابهت‌های ساختاری بررسی کردیم و همچنین با استفاده از شبکه‌های ساختگی تاثیر میزان مشاهدات و میزان جامعه‌بندی شدن شبکه زیرین بر روی عملکرد مدل‌ها را مطالعه نمودیم. نتایج نشان می‌دهد که مدل پیشنهادی علاوه بر سرعت بالا در انجام فرآیند استنتاج، در اکثر مواقع بهترین نتایج را نسبت به دیگر روش‌ها تولید می‌کند.

فصل ۵

جمع‌بندی

تا کنون مطالعات بسیاری برای استنتاج شبکه‌ها با استفاده از اطلاعات انتشار انجام شده است اما غالباً این مطالعات از حفظ ویژگی‌های شبکه‌های زیرین غافل می‌شوند. یکی از مهم‌ترین ویژگی‌های شبکه‌های اجتماعی، ساختار مولفه‌ای است و الگوریتم‌های تشخیص جامعه نیاز به ساختار شبکه دارند تا جوامع موجود در شبکه را استخراج کنند. بنابراین، این الگوریتم‌ها نمی‌توانند بر روی شبکه‌های حاصل از روش‌های قبلی بکار گرفته شوند. علاوه بر این، یکی از نقاط ضعف اصلی کارهای قبلی مربوط به پیچیدگی زمانی آن‌ها بوده است. در این پایان‌نامه، یک روش برای استنتاج شبکه‌ها از داده‌های انتشار با استفاده از گذارهای مارکوف و شباهت گره به گره محاسبه‌شده از اطلاعات انتشار پیشنهاد شده است که می‌تواند ویژگی‌های ساختاری را حفظ کند. این ادعا با مقایسه ساختارهای شبکه‌های اصلی و استنتاج‌شده با استفاده از روش پیشنهادی تایید می‌گردد. علاوه بر این، ما از سه دسته معیار برای ارزیابی صحت استنتاج پیوندها، ارزیابی شباهت شبکه‌های استنتاج شده و ساختارهای شبکه برای روش پیشنهادی و روش‌های مرتبط مختلف استفاده کردیم. نتایج نشان داد که الگوریتم ما با دقت شبکه‌ها را استنتاج می‌کند و در عین حال این کار را با حفظ ساختار آنها انجام می‌دهد. علاوه بر این، روش پیشنهادی نسبت به رقبای خود به مدت کمتری برای دستیابی به همان دقت یا دقت بالاتر نیاز دارد. ما نشان دادیم که روش پیشنهادی در یک شبکه با ساختار جامعه‌ای بهتر و سریع‌تر عمل می‌کند و زمانی که ساختار مولفه‌ای به ساختار تصادفی تبدیل می‌شود، سرعت آن کاهش می‌یابد. روش پیشنهادی قادر به انجام عملکرد مناسب در شبکه‌های اجتماعی واقعی است زیرا دارای ساختار مولفه‌ای هستند. علاوه بر این، عملکرد روش پیشنهادی مستقل از طول آبشارها است. همچنین، ما یک نسخه توزیع شده از الگوریتم پیشنهادی را در چارچوب MapReduce برای پردازش داده‌های بزرگ در جهان واقعی طراحی کرده‌ایم.

در حل این مساله این فرض را داشتیم که مشاهدات ما از فرآیندهای انتشار انجام شده کامل است و زمان انتشار تمام رئوسی که در یک آبشار شرکت کرده‌اند را در اختیار داریم. این فرض در حالت کلی ممکن است برقرار نباشد و در آن صورت گراف استنتاجی توسط مدل پیشنهادی در حفظ ویژگی‌های ساختاری موفق عمل نخواهد کرد. در ادامه این کار می‌توان به بررسی این مساله بدون فرض کامل بودن مشاهدات پرداخت.

Bibliography

[1] M. Gomez Rodriguez, J. Leskovec, and A. Krause, "Inferring networks of diffusion and influence," in *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '10, (New York, NY, USA), pp.1019–1028, ACM, 2010.

[2] P. Kumar and A. Sinha, "Information diffusion modeling and analysis for socially interacting networks," *Social Network Analysis and Mining*, vol.11, pp.1–18, 2021.

[3] D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010.

[4] M. Eftekhar, Y. Ganjali, and N. Koudas, "Information cascade at group scale," in *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '13, (New York, NY, USA), pp.401–409, ACM, 2013.

[5] T. Trolliet, N. Cohen, F. Giroire, L. Hogie, and S. Pérennes, "Interest clustering coefficient: a new metric for directed networks like Twitter," *Journal of Complex Networks*, vol.10, no.1, 2021.

[6] H. Kwak, C. Lee, H. Park, and S. Moon, "What is twitter, a social network or a news media?," in *Proceedings of the 19th international conference on World wide web*, pp.591–600, 2010.

[7] J. Xie, S. Kelley, and B. K. Szymanski, "Overlapping community detection in networks: the state of the art and comparative study," *ACM Computing Surveys (CSUR)*, vol.45, no.4, pp.43:1–43:35, 2013.

[8] W. Chen, "Discovering communities by information diffusion," in *Fuzzy Systems and Knowledge Discovery (FSKD), 2011 Eighth International Conference on*, vol.2, pp.1123–1132, 2011.

[9] J. Scripps, P.-N. Tan, and A.-H. Esfahanian, "Node roles and community structure in networks," in *Proceedings of the 9th WebKDD and 1st SNA-KDD 2007 workshop on Web mining and social network analysis*, WebKDD/SNA-KDD '07, (New York, NY, USA), pp.26–35, ACM, 2007.

[10] E. Bakshy, I. Rosenn, C. Marlow, and L. Adamic, "The role of social networks in information diffusion," in *Proceedings of the 21st International Conference on World Wide Web*, WWW '12, (New York, NY, USA), pp.519–528, ACM, 2012.

[11] J. Goldenberg, B. Libai, and E. Muller, "Talk of the network: A complex systems look at the underlying process of word-of-mouth," *Marketing letters*, vol.12, pp.211–223, 2001.

[12] N. Barbieri, F. Bonchi, and G. Manco, "Cascade-based community detection," in *WSDM* (S. Leonardi, A. Panconesi, P. Ferragina, and A. Gionis, eds.), pp.33–42, ACM, 2013.

[13] C. Gao, Y. Wang, Z. Wang, X. Li, and X. Li, "Pairwise-interactions-based bayesian inference of network structure from information cascades," in *Proceedings of the ACM Web Conference 2023*, WWW '23, (New York, NY, USA), p.102–110, Association for Computing Machinery, 2023.

[14] H. Li, C. Xia, T. Wang, S. Wen, C. Chen, and Y. Xiang, "Capturing dynamics of information diffusion in sns: A survey of methodology and techniques," *ACM Computing Surveys (CSUR)*, vol.55, no.1, pp.1–51, 2021.

[15] I. Brugere, B. Gallagher, and T. Y. Berger-Wolf, "Network structure inference, a survey: Motivations, methods, and applications," *ACM Computing Surveys (CSUR)*, vol.51, no.2, pp.1–39, 2018.

[16] F. Zhou, X. Xu, G. Trajcevski, and K. Zhang, "A survey of information cascade analysis: Models, predictions, and recent advances," *ACM Computing Surveys (CSUR)*, vol.54, no.2, pp.1–36, 2021.

[17] A. Alpay, D. Demir, and J. Yang, "Fastinf: A fast algorithm to infer social networks from cascades," 2011.

[18] M. Gomez-Rodriguez and B. Schölkopf, "Submodular inference of diffusion networks from multiple trees," in *Proceedings of the 29th International Conference on Machine Learning*, (New York, NY, USA), pp.489–496, Omnipress, 2012.

[19] S. A. Myers and J. Leskovec, "On the convexity of latent social network inference," in *NIPS* (J. D. Lafferty, C. K. I. Williams, J. Shawe-Taylor, R. S. Zemel, and A. Culotta, eds.), pp.1741–1749, Curran Associates, Inc., 2010.

[20] M. Gomez-Rodriguez, D. Balduzzi, and B. Schölkopf, "Uncovering the temporal dynamics of diffusion networks," in *Twenty-eighth International Conference on Machine Learning, Bellevue, Washington* (L. Getoor and T. Scheffer, eds.), pp.561–568, Omnipress, 2011.

[21] M. Gomez-Rodriguez, J. Leskovec, and B. Schölkopf, "Structure and dynamics of information pathways in online media," in *WSDM* (S. Leonardi, A. Panconesi, P. Ferragina, and A. Gionis, eds.), pp.23–32, ACM, 2013.

[22] Q. Tan, Y. Liu, and J. Liu, "Motif-aware diffusion network inference," *International Journal of Data Science and Analytics*, vol.9, no.4, pp.375–387, 2020.

[23] K. Han, Y. Tian, Y. Zhang, L. Han, H. Huang, and Y. Gao, "Statistical estimation of diffusion network topologies," in *2020 IEEE 36th International Conference on Data Engineering (ICDE)*, pp.625–636, IEEE, 2020.

[24] M. Eslami, H. R. Rabiee, and M. Salehi, "Dne: A method for extracting cascaded diffusion networks from social networks," in *SocialCom/PASSAT*, pp.41–48, IEEE, 2011.

[25] C. Gray, L. Mitchell, and M. Roughan, "Bayesian inference of network structure from information cascades," *IEEE Transactions on Signal and Information Processing over Networks*, vol.6, pp.371–381, 2020.

[26] Q. Hu, S. Xie, S. Lin, S. Wang, and S. Y. Philip, "Clustering embedded approaches for efficient information network inference," *Data Science and Engineering*, vol.1, no.1, pp.29–40, 2016.

[27] S. Hu, B. Cautis, Z. Chen, L. Chan, Y. Geng, and X. He, "Model-free inference of diffusion networks using rkhs embeddings," *Data Mining and Knowledge Discovery*, vol.33, no.2, pp.499–525, 2019.

[28] Z. T. Kefato, N. Sheikh, and A. Montresor, "Refine: representation learning from diffusion events," in *Machine Learning, Optimization, and Data Science: 4th International Conference*, pp.141–153, Springer, 2019.

[29] R. D. Malmgren, D. B. Stouffer, A. E. Motter, and L. A. N. Amaral, "A Poissonian explanation for heavy tails in e-mail communication," *Proceedings of the National Academy of Sciences*, vol.105, no.47, pp.18153–18158, 2008.

[30] N. Barbieri, F. Bonchi, and G. Manco, "Influence-based network-oblivious community detection," in *ICDM*, pp.955–960, 2013.

[31] P. Jaccard, "Étude comparative de la distribution florale dans une portion des Alpes et des Jura," *Bulletin del la Société Vaudoise des Sciences Naturelles*, vol.37, pp.547–579, 1901.

[32] A. Lancichinetti, F. Radicchi, J. J. Ramasco, and S. Fortunato, "Finding statistically significant communities in networks," *PloS one*, vol.6, no.4, p.e18961, 2011.

[33] C. D. Manning, P. Raghavan, and H. Schütze. *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008.

[34] T. Yang, R. Jin, Y. Chi, and S. Zhu, "A bayesian framework for community detection integrating content and link," in *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, pp.615–622, 2009.

[35] G.-J. Qi, C. C. Aggarwal, and T. S. Huang, "Community detection with edge content in social media networks," in *ICDE* (A. Kementsietsidis and M. A. V. Salles, eds.), pp.534–545, IEEE Computer Society, 2012.

[36] T. Garrels, A. Khodabakhsh, B. Y. Renard, and K. Baum, "Lazyfox: fast and parallelized overlapping community detection in large graphs," *PeerJ Computer Science*, vol.9, p.e1291, 2023.

[37] A. Lancichinetti and S. Fortunato, “Benchmarks for testing community detection algorithms on directed and weighted graphs with overlapping communities,” *Physical Review E*, vol.80, no.1, p.016118, 2009.

[38] J. Leskovec and R. Sosič, “Snap: A general-purpose network analysis and graph-mining library,” *ACM Trans. Intell. Syst. Technol.*, vol.8, no.1, 2016.

[39] J. Leskovec, L. Backstrom, and J. Kleinberg, “Memetracker: tracking news phrases over the web,” 2008.

[40] L. Weng, F. Menczer, and Y.-Y. Ahn, “Virality prediction and community structure in social networks,” *Scientific reports*, vol.3, 2013.

واژه‌نامه

الف

ابرپارامتر ..... Hyper-parameter
آبشار ..... Cascade
اجتماع ..... Community
ارجاع ..... Reference
آستانه ..... Threshold
استنتاج ..... Inference
اطلاعات ..... Information
اطلاعات متقابل بهنجار .... Normalized Mutual Information
اصلی ..... Original
الگوی مثلثی ..... Clique
آلودگی ..... Infection
انتشار ..... Diffusion

ب

برچسب ..... Label
برچسب زمانی ..... Timestamp
برخورد ..... Hit
برخط ..... Online
بردار آبشار ..... Cascade Vector
بیشینه ..... Maximum
بیشینه درست‌نمایی ..... Maximum Likelihood
بیشینه‌گر احتمال پسین .. Maximum a Posteriori
بهینه ..... Optimum
بیزی ..... Bayesian
بدون جهت (گراف) ..... Undirected
بازنمایی ..... Representation

پ

پارامتر ..... Parameter
پیوسته ..... Continuous
پویا ..... Dynamic

ت

تاثیرگذار ..... Influencer
تعامل ..... Interaction
توالی ..... Sequence
تابع بقا ..... Survival function
تعبیه ..... Embedding
تشابه ..... Similarity
ترتیب ..... Order
تخمین ..... Estimate
تصفیه ..... Filter

ج

جامعه ..... Community
جهت ..... Direction
جهت‌دار ..... Directed

چ

چگال ..... Dense
چگالی ..... Density
چارچوب ..... Framework

ح

حریم شخصی ..... Privacy
حساب ..... Account

خ

خوشه‌بندی ..... Clustering
خوشه ..... Cluster
خودرمزنگار ..... Auto-encoder

د

دنباله ..... Sequence
درخت ..... Tree
دقت ..... Accuracy
دانش پیشین ..... Prior Knowledge
دنبال کردن ..... Following

ر

رفتار ..... Behavior
راس ..... Node

ز

زیرین ..... Underlying
زیرمولفه‌ای ..... Sub-modular
زنجیره ..... Chain
زوج‌گرا ..... Pairwise

س

ساختار ..... Structure
سلسله‌مراتب ..... Hierarchy
سیاق ..... Context

ش

شبکه ..... Network
شباهت ..... Similarity
شاخص ..... Index
شاخص جاکارد ..... Jaccard Index
شار ..... Conductance

ع

عملکرد ..... Performance

غ

غیرفعال ..... Inactive

ف

فرآیند ..... Process
فضا ..... Space
فعال ..... Active
فاصله ..... Distance

ق

قانون ..... Rule

ک

کاربر ..... User

گ

گراف ..... Graph

گره ..... Node

گام‌به‌گام ..... Iterative

گذار ..... Transition

م

محتوا ..... Content

مشاهده ..... Observation

مولفه ..... Module, Component

مرکزی ..... Central

مرزی ..... Boundary

مجاور ..... Neighbor

متصل ..... Connected

منزوی ..... Isolated

مقیاس‌پذیر ..... Scalable

هم‌روند ..... Concurrent

مطالعه تفصیلی ..... Survey

مدل ..... Model

مارکوف ..... Markov

محتوا ..... Content

ن

ناهمگن ..... Heterogeneous

نسبی ..... Relative

نمایه ..... Index

نقشه حرارتی ..... Heat map

نماد ..... Symbol

نمایی ..... Exponential

نسبی ..... Relative

و

ویژگی ..... Characteristic

واقعی ..... Real

وزن ..... Weight

وقوع ..... Occurrence

هـ

همسایه ..... Neighbor

همگن ..... Homogeneous

هم‌گرایی ..... Convergence

همبند (گراف) ..... Connected

ی

یال ..... Edge

Abstract

The fast growth of social networks and their data access limitations in recent years has led to increasing difficulty in obtaining the complete topology of these networks. However, diffusion information over these networks is available, and many algorithms have been proposed to infer the underlying networks using this information. The previously proposed algorithms only focus on inferring more links and ignore preserving the critical topological characteristics of the underlying social networks. In this paper, we propose a novel method to infer the underlying network while preserving its structural properties. It is based on the Markov transition matrix derived from time series cascades, as well as the node-node similarity that can be observed in the cascade behavior from a structural point of view. In addition, the presented method has linear time complexity (increases linearly with the number of nodes, number of cascades, and square of the average length of cascades), and its distributed version in the MapReduce framework is also scalable. We applied the proposed approach to both real and synthetic networks. The experimental results showed that our method has higher accuracy and lower run time while maintaining structural properties, including modular structure, degree distribution, connected components, density, and clustering coefficients, than well-known network inference methods.

Keywords: Social Networks, Link Inference, Information Diffusion

Sharif University of Technology

Department of Computer Engineering

Bachelor Thesis

Analysing and Modeling Observed Signals and Graph Structure in Social Networks

By

Aryan Ahadinia

Supervised by

Hamid R. Rabiee

August 2023